AREM · UNIVERSIDAD DE LA SABANA · MÓDULO 05

Arquitectura de Infraestructura y Topologías

Dónde corre realmente lo que documentamos en el módulo anterior

Objetivo: comprender los conceptos clave de infraestructura tecnológica, representarlos en un diagrama de despliegue y evaluar su efecto sobre rendimiento, disponibilidad y escalabilidad.

Profesor: Ing. César Augusto Vega Fernández

01 · OBJETIVO

Qué se lleva del módulo

Cuatro capacidades, no una lista de tecnologías

01 **Ubicar**

Llevar cada contenedor del diagrama C4 a un nodo de infraestructura concreto.

02 **Elegir**

Seleccionar topología y modelo de despliegue con criterios explícitos, no por moda.

03 **Justificar**

Explicar qué cuesta cada buena práctica y cuándo no se justifica pagarla.

04 **Preparar**

Dejar el diagrama listo para el análisis de amenazas y el de riesgos que vienen después.

ENTREGABLE · TALLER 4

- Diagrama de despliegue del sistema del cliente, con sus nodos y zonas de red
- Topología elegida, con la justificación de por qué esa y no otra
- Tabla de buenas prácticas aplicadas y su costo asumido
- Lista de puntos únicos de falla detectados

Del contenedor al nodo

El Módulo 4 dijo qué se despliega por separado; este dice dónde corre

MÓDULO 4 · CONTENEDORES		MÓDULO 5 · NODOS
Portal Paciente (React)		CDN pública
App Clínica (Angular)	¿dónde corre? →	Servidor de aplicaciones · sede principal
API de Aplicación (Spring Boot)		Servidor de aplicaciones · sede principal
Servicio de Integración (Node.js)		Servidor de integración · DMZ
BD Clínica (PostgreSQL)		Servidor de base de datos · red interna

La relación no es uno a uno: dos contenedores pueden compartir un nodo, y un contenedor puede replicarse en varios. Ahí es donde aparecen las decisiones de infraestructura, y por eso no basta con el diagrama del Módulo 4.

Las cuatro capas de la arquitectura técnica

El vocabulario mínimo para leer un diagrama de infraestructura

Capa de red	Firewalls, balanceadores, enrutamiento, VPN, zonas de seguridad.	*Define quién puede hablar con quién.*
Capa de cómputo	Servidores físicos, máquinas virtuales, contenedores, funciones sin servidor.	*Define dónde se ejecuta el código.*
Capa de datos	Bases de datos, almacenamiento de archivos, caché, respaldos.	*Define dónde vive la información y cuánto sobrevive.*
Capa de observabilidad	Registros, métricas, trazas, alertas.	*Define si alguien se entera cuando algo falla.*

La cuarta capa es la que más se omite en los proyectos de clase, y es la única que permite saber si las otras tres están funcionando.

Cómo se construye un diagrama de despliegue

Cuatro pasos, en este orden

PASO 1

Listar los nodos

Un nodo es un lugar de ejecución: un servidor, una máquina virtual, un servicio administrado en la nube, un dispositivo. Se listan antes de dibujar nada.

PASO 2

Ubicar los contenedores

Cada contenedor del diagrama C4 se asigna a un nodo. Si dos comparten nodo, se anota; si uno se replica, se dibujan las réplicas.

PASO 3

Trazar las zonas de red

Se agrupan los nodos por zona: pública, DMZ, red interna. Toda conexión que cruza una zona se marca.

PASO 4

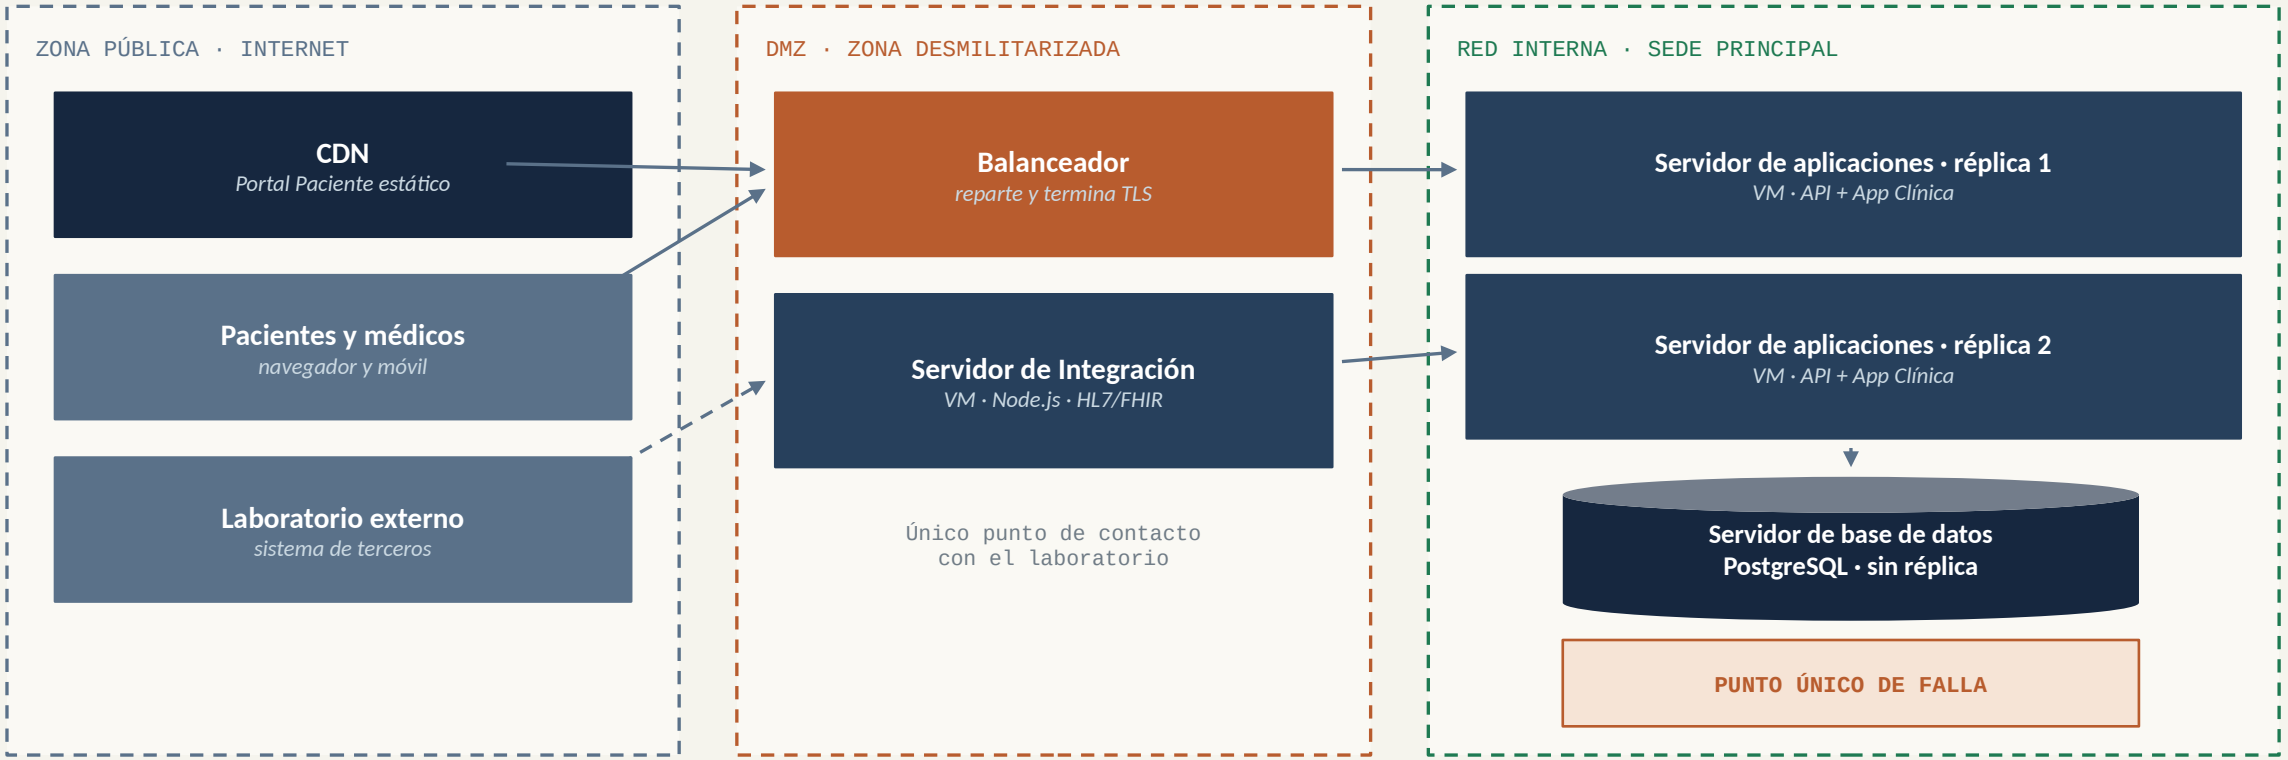
Etiquetar y validar

Cada nodo con su tecnología y capacidad; cada conexión con su protocolo. Se valida buscando qué se cae si falla cada nodo.

La validación del paso 4 es la parte importante: un diagrama de despliegue que no se ha sometido a la pregunta «¿qué se cae si falla esto?» es solo un inventario de servidores.

Despliegue de la Clínica Salud Viva

Los contenedores del Taller 3, ubicados en nodos y zonas



Dos réplicas de aplicación protegen contra la caída de un servidor, pero la base de datos sin réplica anula esa protección: si cae, no importa cuántas aplicaciones haya.

Modelos de despliegue

Cuatro opciones y el criterio para elegir entre ellas

On-premise

Infraestructura propia en las instalaciones de la organización.

CUÁNDO

Cuando la normativa exige que el dato no salga del país o del edificio.

Costo fijo alto, escalado lento

Nube pública

Infraestructura contratada a un proveedor: AWS, Azure, GCP.

CUÁNDO

Cuando la demanda es variable y el equipo es pequeño.

Costo variable, dependencia del proveedor

Híbrida

Parte propia, parte contratada.

CUÁNDO

Cuando hay datos sensibles que no pueden salir, pero cargas que sí.

Dos operaciones que mantener

Multinube

Varios proveedores simultáneos.

CUÁNDO

Cuando la continuidad del negocio no admite depender de uno solo.

Complejidad alta; rara vez se justifica

Para el caso de la clínica: los datos de historia clínica tienen restricciones normativas, así que el modelo híbrido es el punto de partida razonable.

Cinco formas de organizar el sistema

Con el criterio de cuándo cada una es la decisión correcta

TOPOLOGÍA	QUÉ ES	CUÁNDO SÍ	QUÉ CUESTA
Monolítica	Todo en un servidor	Sistema pequeño, equipo de pocas personas, dominio estable	*Escalar obliga a escalar todo junto*
Dos capas	Cliente y servidor	Aplicaciones de escritorio o internas con pocos usuarios	*La lógica queda en el cliente y es difícil de cambiar*
Tres capas	Cliente, backend y base de datos	La opción por defecto para la mayoría de sistemas web	*Suficiente para casi todo lo que verán en el curso*
Microservicios	Servicios independientes y desplegables por separado	Varios equipos trabajando en paralelo sobre un dominio grande	*Complejidad operativa alta: exige monitoreo y automatización*
Sin servidor	Funciones que se ejecutan por evento	Cargas intermitentes o muy variables	*Costo impredecible y dependencia fuerte del proveedor*

Regla para el curso: empiecen por tres capas y justifiquen cualquier cosa más compleja. Los microservicios son una respuesta a un problema de organización, no de tecnología.

Lo que cuesta cada garantía

Ninguna de estas prácticas es gratis; todas se deciden

Redundancia

Duplicar componentes para que la caída de uno no tumbe el servicio.

COSTO — Se paga el doble de infraestructura, esté o no en uso.

CUÁNDO — Cuando la indisponibilidad cuesta más que el servidor duplicado.

Balanceo y autoescalado

Repartir la carga y agregar capacidad automáticamente en los picos.

COSTO — Costo variable difícil de presupuestar; exige que la aplicación sea replicable.

CUÁNDO — Cuando la demanda tiene picos marcados y predecibles.

Segmentación de red

Separar zonas para que un intruso no alcance todo el sistema.

COSTO — Más reglas que mantener y más puntos donde algo puede quedar bloqueado.

CUÁNDO — Siempre que existan datos sensibles: en salud no es opcional.

Observabilidad

Registros, métricas y trazas para saber qué está pasando.

COSTO — Almacenamiento, licencias y tiempo del equipo configurando alertas.

CUÁNDO — Siempre. Es la práctica con mejor relación costo-beneficio.

Infraestructura como código

Hoy la topología no se dibuja: se declara

infraestructura.tf

```
resource "servidor" "aplicaciones" {
  cantidad = 2
  zona     = "red_interna"
  memoria  = "8GB"
  ejecuta  = ["api", "app_clinica"]
}

resource "base_datos" "clinica" {
  motor    = "postgresql"
  zona     = "red_interna"
  replicas = 1   # <-- decisión pendiente
  respaldo = "diario"
}
```

El entorno es reproducible

Levantar una copia idéntica para pruebas deja de ser un proyecto y pasa a ser un comando.

Los cambios se revisan

Aumentar de una réplica a dos es una línea, y esa línea pasa por revisión igual que el código.

El diagrama y la realidad no divergen

El archivo es la infraestructura, así que no puede quedar desactualizado respecto a ella.

Queda historial

Git muestra cuándo se cambió la capacidad de un servidor y quién lo aprobó.

Herramientas: Terraform, OpenTofu, Pulumi, Bicep. Para el Taller 4 basta con el diagrama; el archivo declarativo es opcional.

Buscar los puntos únicos de falla

El paso que convierte un inventario en un análisis

Un punto único de falla es cualquier elemento cuya caída deja el servicio inutilizable, sin importar cuán redundante sea el resto.

01 El nodo compartido

Dos contenedores en el mismo servidor caen juntos.

En la clínica: la API y la App Clínica comparten servidor.

02 La base de datos sin réplica

Toda la redundancia de aplicación se vuelve inútil.

El caso de la diapositiva 6.

03 El proveedor no sustituible

Un tercero del que no existe alternativa contratada.

El laboratorio externo de la clínica.

04 La persona única

Una sola persona sabe operar un componente.

No aparece en el diagrama, y es el más común.

Esta lista es el insumo directo del Módulo 9: cada punto único de falla es un riesgo arquitectónico que hay que ubicar en la matriz de impacto y probabilidad.

Con qué dibujarlo

Todas gratuitas o con capa gratuita suficiente

draw.io

GRATUITO · WEB

Bibliotecas de formas de AWS, Azure y redes incorporadas. La misma herramienta del Taller 3.

Recomendada

Iconos oficiales de nube

GRATUITO

AWS Architecture Icons y Azure Architecture Icons. Dan credibilidad al diagrama frente al cliente.

Complemento de draw.io

Structurizr · vista de despliegue

GRATUITO CON DOCKER

Si ya modelaron el C4 en DSL, la vista de despliegue sale del mismo archivo.

Para quien siguió el camino del DSL

Terraform u OpenTofu

GRATUITO · CÓDIGO ABIERTO

Para declarar la infraestructura en vez de dibujarla. No se exige en el taller.

Opcional, para ir más lejos

Se califica que el diagrama tenga nodos, zonas y protocolos etiquetados. El acabado gráfico no suma puntos.

Mapa de infraestructura en clase · 40 minutos

En equipos, sobre el sistema del cliente real

10 min	**Listar nodos y zonas** Enumeren los lugares de ejecución del sistema del cliente y agrúpenlos en zonas de red. Si el cliente no da el detalle, marquen el supuesto.
15 min	**Ubicar los contenedores** Tomen su diagrama del Taller 3 y asignen cada contenedor a un nodo. Anoten los que comparten nodo.
10 min	**Etiquetar** Tecnología y capacidad por nodo; protocolo por conexión. Marquen las conexiones que cruzan zona.
5 min	**Buscar el punto de falla** Pregunta por nodo: si este se cae, ¿qué deja de funcionar? Lo que quede sin respuesta es un hallazgo.

ERRORES QUE VAMOS A BUSCAR

- Nodos sin tecnología ni capacidad
- Zonas de red no dibujadas
- Microservicios propuestos sin justificar
- Ningún punto único de falla detectado

Al terminar: guarden el diagrama. Se reutiliza en el Módulo 6 para los límites de confianza y en el Módulo 9 para el análisis de riesgos.

PARA LLEVARSE

Infraestructura en cuatro ideas

01 **El contenedor no es el nodo**

Documentar qué se despliega no dice dónde corre; son dos diagramas distintos.

02 **Toda garantía tiene precio**

Redundancia, autoescalado y observabilidad se deciden, no se dan por sentadas.

03 **Tres capas por defecto**

Cualquier topología más compleja necesita justificación explícita.

04 **La infraestructura se declara**

Escribirla como código es lo que evita que el diagrama y la realidad se separen.

Próximo paso: Taller 4 · diagrama de despliegue del cliente, con zonas, protocolos y puntos únicos de falla.

LECTURAS RECOMENDADAS

NIST SP 500-292 — Cloud Computing Reference Architecture

The Twelve-Factor App — twelve-factor.net

AWS Well-Architected Framework

Google SRE Book — capítulos de disponibilidad

Terraform / OpenTofu — documentación oficial