FUNDAMENTOS DE PROCESAMIENTO DE LENGUAJE NATURAL

Sesión 5

# Comparar representaciones con rigor experimental

Preprocesamiento, BoW frente a TF-IDF y fugas de información

Martes 15 de septiembre de 2026 · Universidad de La Sabana

# Qué vamos a responder hoy

1. ¿Importa el orden entre quitar tildes y lematizar?
2. ¿Cómo se comparan dos representaciones de forma justa?
3. ¿Cuánto nos puede engañar una sola partición de entrenamiento y prueba?
4. ¿Por dónde se cuela una fuga de información en la evaluación?

# Cómo se organiza la sesión

Cada bloque corresponde a una parte del notebook reto_clase_sesion5.ipynb

BLOQUE 1

## El orden del preprocesamiento

Partes 0 y 1

~30 min

BLOQUE 2

## BoW frente a TF-IDF en condiciones equivalentes

Parte 2

~45 min

BLOQUE 3

## Fuga de información por duplicados

Parte 3

~20 min

BLOQUE 4

## Taller de entregables del Módulo 2

Parte 4

~35 min

# Dónde estamos: entregables del Módulo 2

Entrega de las tres actividades: domingo 27 de septiembre

ACTIVIDAD 1 · 10 %

## Infografía de una página

Diseño conceptual de un pipeline de NLP. Insumo: ficha de la Sesión 4.

ACTIVIDAD 2 · 10 %

## Informe PDF, mínimo 2 páginas

BoW frente a TF-IDF en la misma tarea y en condiciones equivalentes. Insumo: Partes 2 y 3 de hoy.

ACTIVIDAD 3 · 10 %

## Presentación, máximo 8 diapositivas

Arquitectura de un clasificador de texto justificada componente por componente. Insumo: Parte 4 de hoy.

Hoy trabajamos directamente sobre las Actividades 2 y 3.

BLOQUE 1

# El orden del preprocesamiento importa

¿Se quitan las tildes antes o después de lematizar?

Partes 0 y 1 del notebook · ~30 min

# Dos caminos, un mismo ejemplo

Frase: **«El chef cocinó la carne muy bien.»**

**A**

| minúsculas | lematizar | quitar stopwords | **quitar tildes** |
|---|---|---|---|
| el chef cocinó la carne muy bien | el · chef · **cocinar** · el · carne · mucho · bien<br>**cocinó → cocinar · VERB** | chef · **cocinar** · carne | chef · **cocinar** · carne<br>resultado final (ya no quedaban tildes) |

**B**

| minúsculas | **quitar tildes** | lematizar | quitar stopwords |
|---|---|---|---|
| el chef cocinó la carne muy bien | el · chef · **cocino** · la · carne · muy · bien | el · chef · **cocino** · el · carne · mucho · bien<br>**cocino → cocino · ADJ** | chef · **cocino** · carne<br>resultado final |

**Mismas etapas, distinto orden:** A entrega «cocinar» (VERB) y B entrega «cocino» (ADJ). En BoW y TF-IDF son dos columnas distintas.

# Quitar tildes primero cambia 6 de 8 tokens

Lema y categoría gramatical del token objetivo en cada opción (spaCy es_core_news_sm)

| Token | A: lema | A: categoría | B: lema | B: categoría | ¿Cambia? |
|---|---|---|---|---|---|
| está | estar | AUX | este | DET | Sí |
| él | el | PRON | el | DET | Sí |
| sí | si | INTJ | si | SCONJ | Sí |
| más | mas | ADV | mas | ADV | No |
| cocinó | cocinar | VERB | cocino | ADJ | Sí |
| papá | papa | NOUN | papa | NOUN | No |
| tú | tu | PRON | tu | DET | Sí |
| llegó | llegar | VERB | llego | ADJ | Sí |

LECTURA

El lematizador es un modelo estadístico: la tilde es parte de la forma que usa para decidir.

Papá no cambia, pero su lema sin tilde, papa, ya se confunde con el tubérculo en ambas opciones.

**Decisión:** lematizar primero y quitar tildes al final.

BLOQUE 2

# BoW frente a TF-IDF en condiciones equivalentes

Lo único que cambia entre las dos corridas es el vectorizador

Parte 2 del notebook · ~45 min

# Qué significa comparar en condiciones equivalentes

Tarea: clasificar el tema de 120 reseñas de restaurantes (servicio, comida, precio, ambiente)

**SE MANTIENE IGUAL**

- El mismo texto limpio
- Las mismas 30 particiones estratificadas (30 % de prueba, semilla 42)
- El mismo modelo: regresión logística con los mismos parámetros
- La misma métrica: exactitud en prueba

**CAMBIA**

**CountVectorizer**

frente a

**TfidfVectorizer**

**Regla:** el vectorizador va dentro del Pipeline y se ajusta solo con el entrenamiento de cada partición.

# Mismas dimensiones, pesos distintos

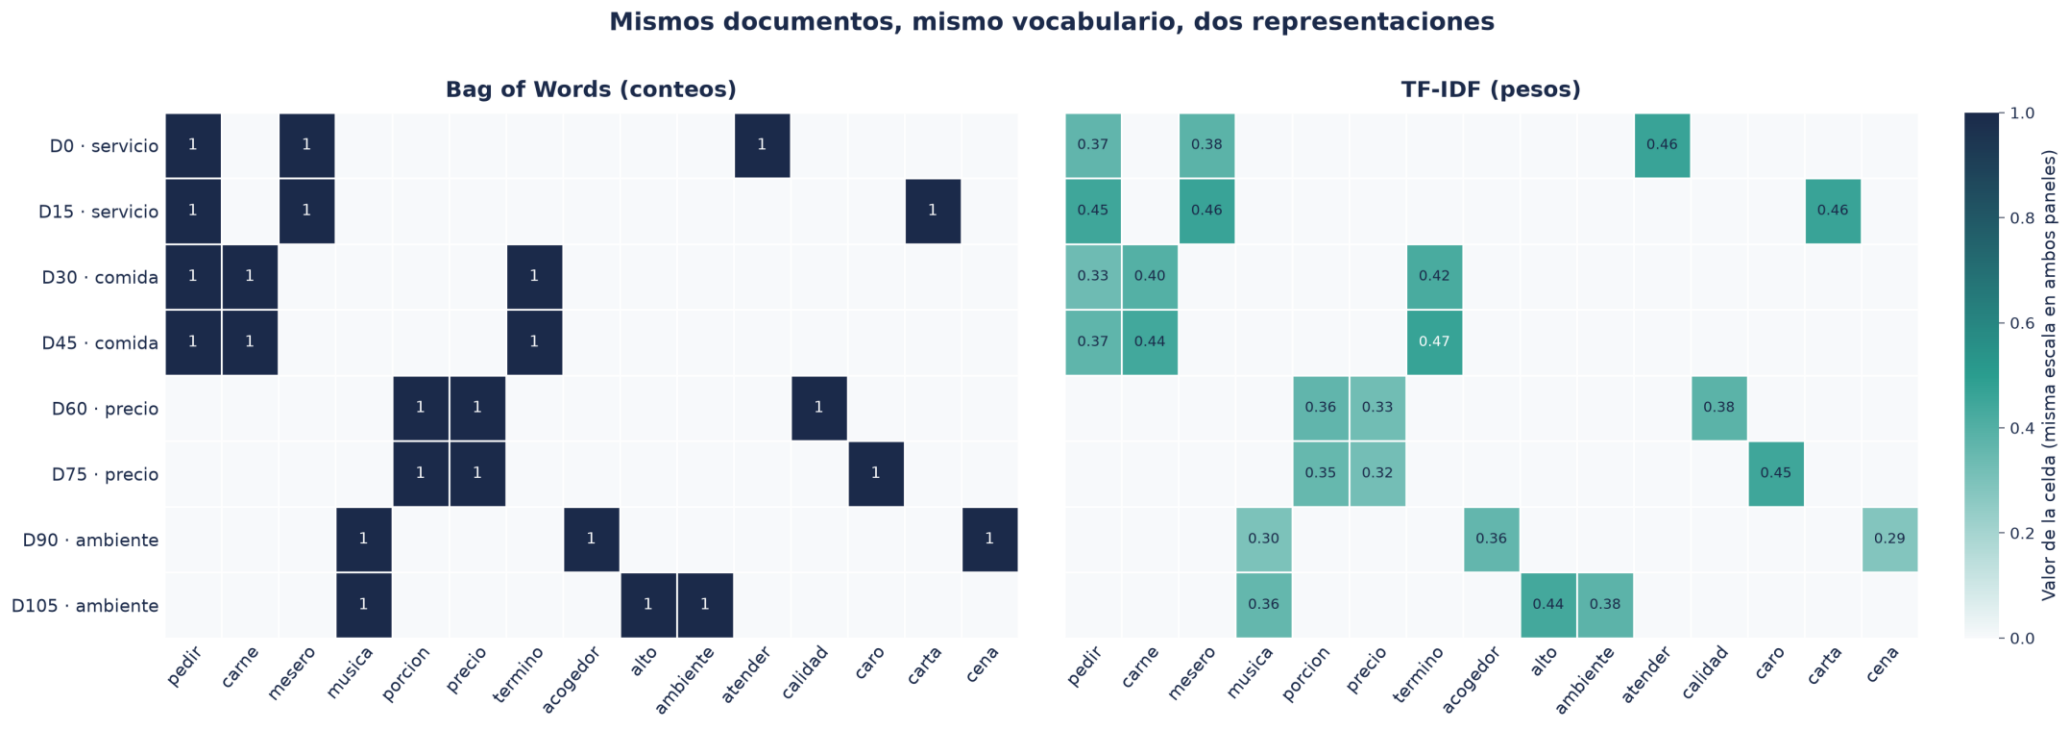
**120 × 426**

documentos × términos
en ambas matrices

**98,7 %**

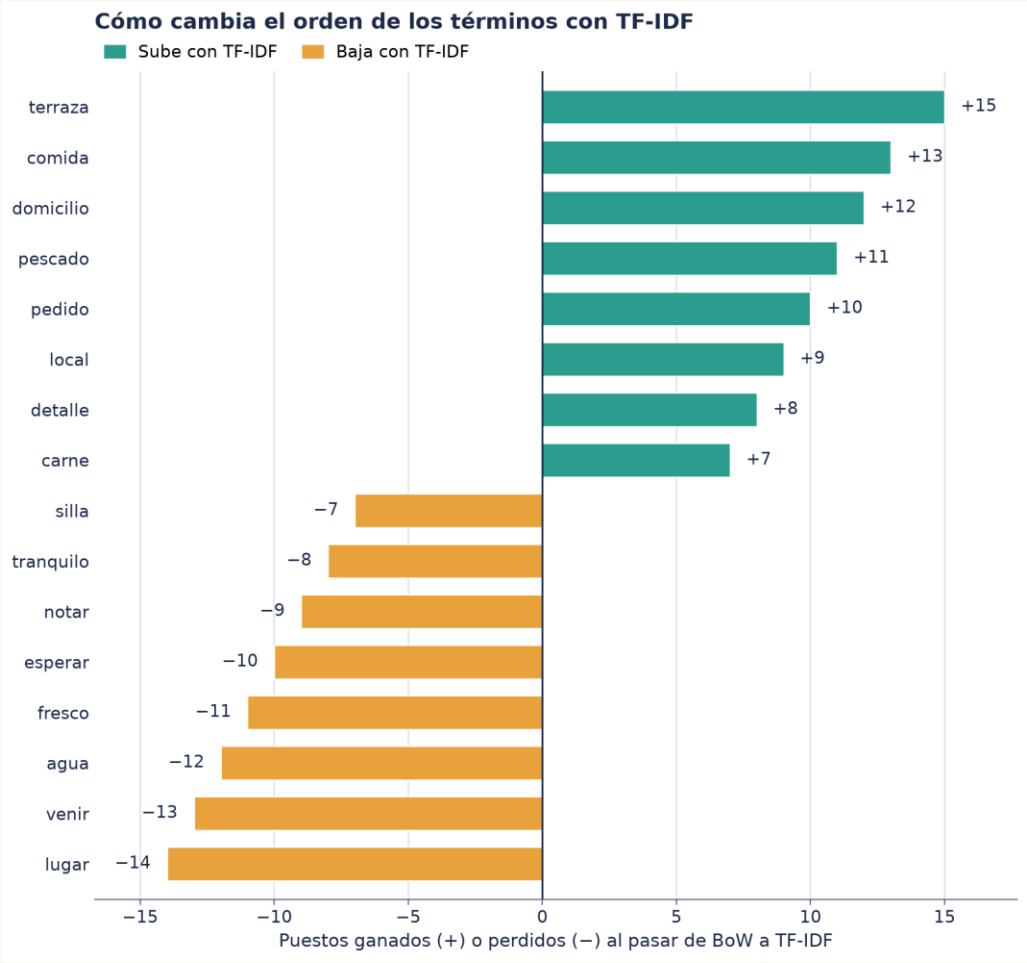
de celdas en cero

BoW muestra conteos enteros; TF-IDF, pesos fraccionarios. Con la misma escala de color, TF-IDF se ve más pálido.



# ¿Por qué cambia el orden de los términos?

Términos presentes en al menos 3 documentos




**REFLEXIÓN 1B**

Terraza, comida, lugar y agua tienen el mismo conteo y el mismo IDF.

Lo que los mueve es la normalización: un término pesa más en una reseña corta que en una larga.

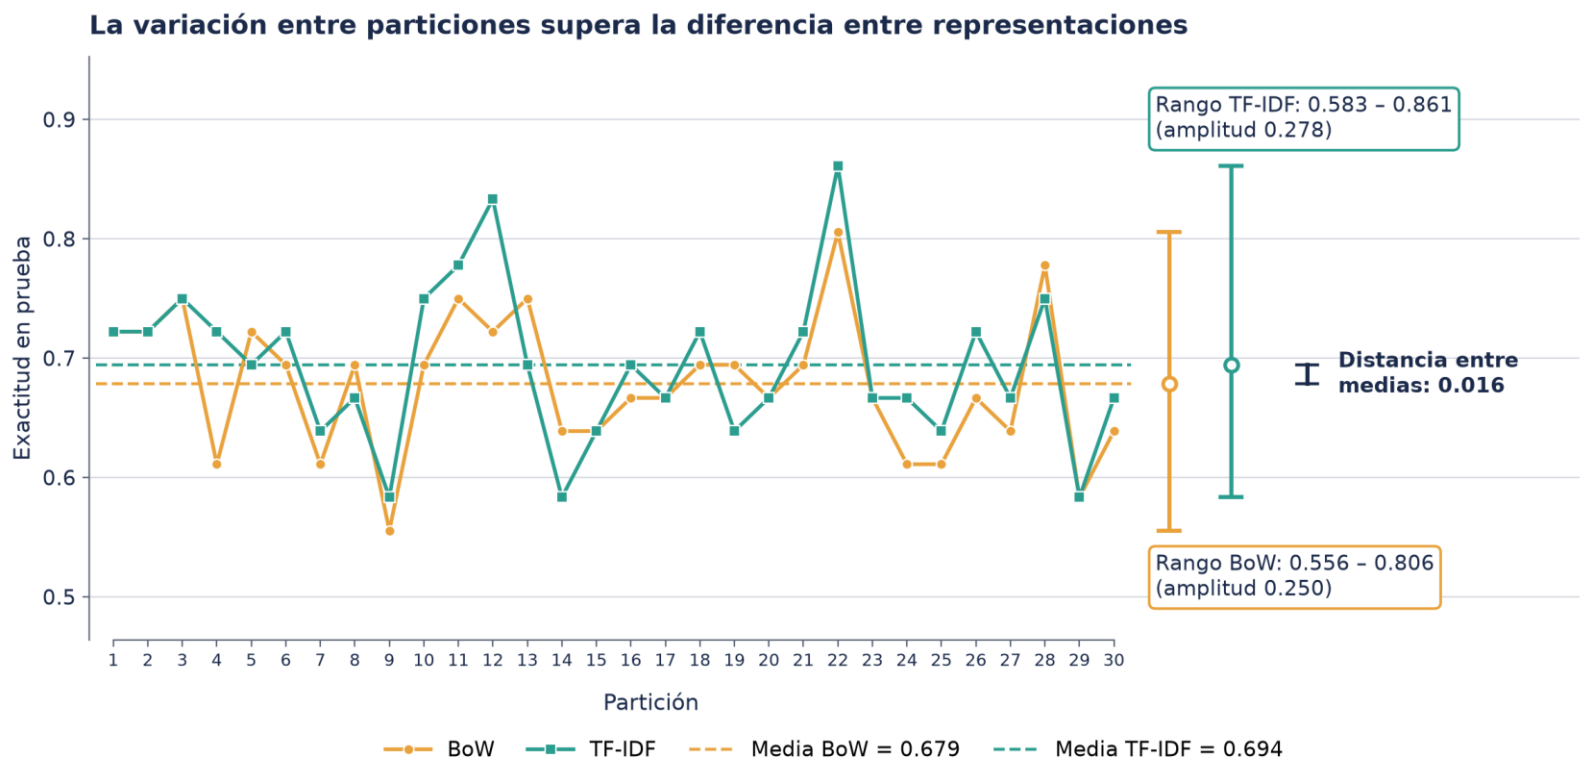
Ningún término aparece en más de 9 de 120 reseñas: el IDF tiene poco margen en este corpus.

# Un cálculo a mano: mismo conteo, mismo IDF, distinto peso

| | término: **terraza** | término: **lugar** |
|---|---|---|
| **Documento**<br>reseña original y texto limpio | *«Había moscas en la terraza y nadie hizo nada al respecto.»*<br>mosca · **terraza**<br>2 términos después de la limpieza | *«Lugar acogedor, luz tenue y música suave. Ideal para una cena en pareja.»*<br>**lugar** · acogedor · luz · tenue · musica · suave · ideal · cena · pareja<br>9 términos después de la limpieza |
| **1. Conteo**<br>veces que aparece en la reseña | **1** | **1** |
| **2. × IDF**<br>ln((1 + 120) / (1 + 3)) + 1 | 1 × 4.41 = **4.41**<br>aparece en 3 de 120 reseñas | 1 × 4.41 = **4.41**<br>aparece en 3 de 120 reseñas |
| **3. ÷ norma**<br>√(suma de los pesos² de la reseña) | 4.41 ÷ 6.74 = **0.654** | 4.41 ÷ 14.05 = **0.314** |

**Lo que cambia es la longitud de la reseña:** en una de 2 términos, «terraza» pesa 0.654; en una de 9, «lugar» pesa 0.314.

# Una sola partición puede decir cualquier cosa




**0.679 ± 0.058**

exactitud BoW

**0.694 ± 0.064**

exactitud TF-IDF

**6 / 16 / 8**

gana BoW / gana TF-IDF / empates

Diferencia: +0.016, menos de un acierto de 36 por partición.

# Cómo se reporta este resultado en el informe

**ASÍ NO**

*“TF-IDF es mejor que BoW: obtuvo 0.861 de exactitud.”*

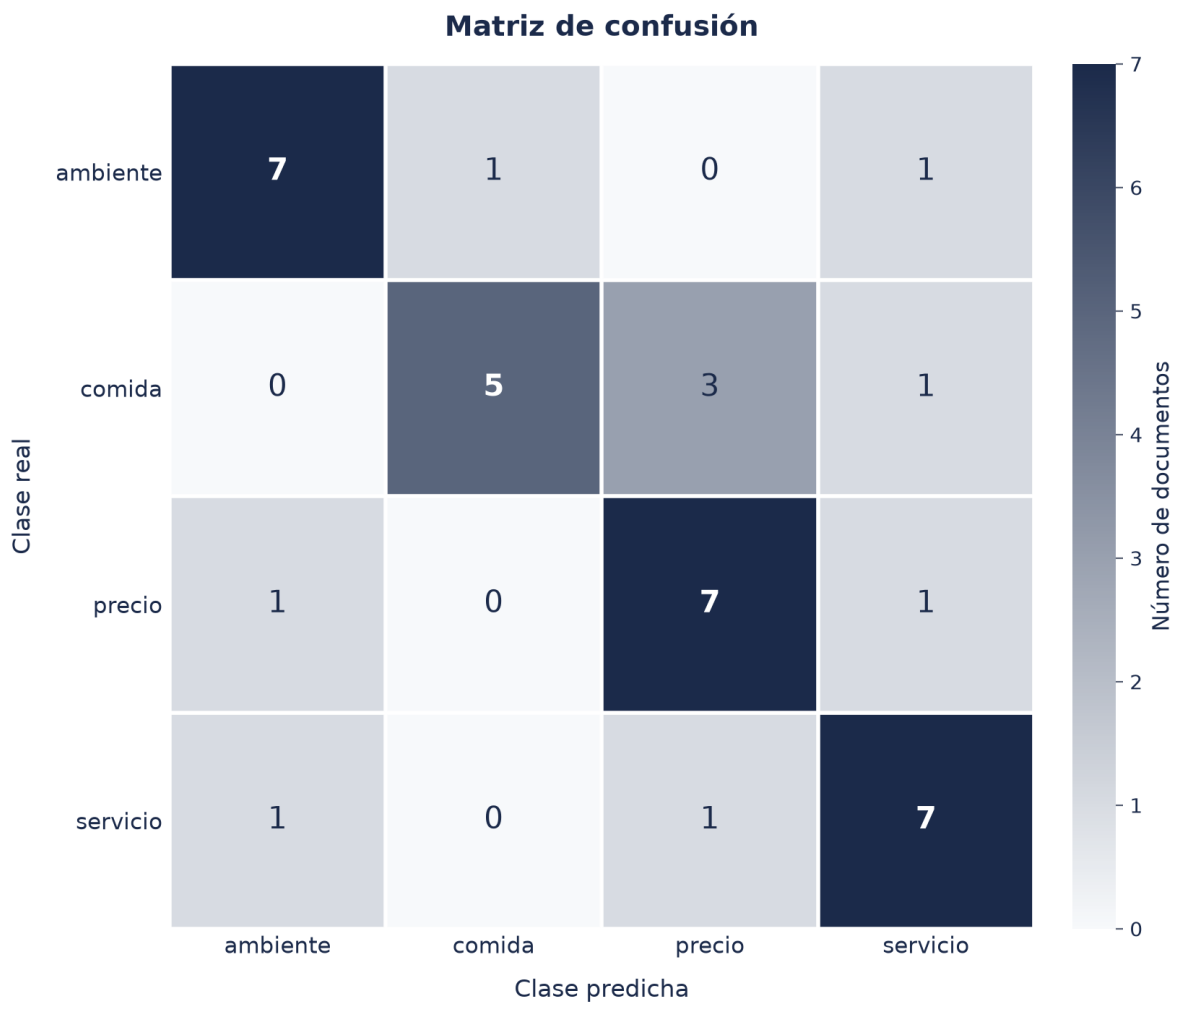
Una sola partición, la más favorable, sin dispersión ni comparación pareada.

**ASÍ SÍ**

*“En 30 particiones, TF-IDF obtuvo 0.694 ± 0.064 y BoW 0.679 ± 0.058. TF-IDF gana 16 de 30, pero la diferencia (+0.016) es menor que la variación entre particiones.”*

Media, desviación, rango y tamaño de la diferencia en aciertos.

# Una partición vista de cerca: ¿qué temas se confunden?




PARA DISCUTIR

En esta partición la exactitud es 0.722.

Tres reseñas de comida se predijeron como precio. ¿Qué palabras comparten esos dos temas?

La matriz de confusión es la base del análisis de errores que pide el Corte 2 del proyecto.

# La otra tarea de la Actividad 2: similitud entre documentos

Similitud coseno media entre reseñas del mismo tema y de temas distintos

| | Mismo tema | Distinto tema | Separación |
|---|---|---|---|
| BoW | 0.026 | 0.007 | +0.020 |
| TF-IDF | 0.021 | 0.005 | +0.016 |

Es el mismo límite de la Sesión 4: sin coincidencias exactas de términos, BoW y TF-IDF no ven parecido.

NINGUNA SEPARA LOS TEMAS

Las reseñas son cortas y casi no comparten términos después de la limpieza.

Mesero y atención hablan de lo mismo, pero son columnas distintas.

# La representación no trabaja sola

Cada experimento cambia una sola cosa respecto a la celda 2c

**SI NO SE ELIMINAN LAS STOPWORDS**

| | BoW | TF-IDF | Gana TF-IDF |
|---|---|---|---|
| Sin stopwords | 0.679 | 0.694 | 16 de 30 |
| Con stopwords | 0.662 | 0.705 | 21 de 30 |

El IDF apaga las palabras vacías que la limpieza dejó. La ventaja de TF-IDF depende del preprocesamiento.

**SI LA TAREA FUERA LA POLARIDAD**

| | BoW | TF-IDF | Azar |
|---|---|---|---|
| Tema (4 clases) | 0.679 | 0.694 | 0.250 |
| Polaridad (2 clases) | 0.398 | 0.397 | 0.500 |

Por debajo del azar: la reseña más parecida suele ser la opuesta (64 % de los casos) y la limpieza borra no, sin y nunca.

**Para la Actividad 3:** la tarea debe ser abordable con el corpus y el preprocesamiento debe servirle a la tarea.

# Un par real: la reseña más parecida dice lo contrario

**POSITIVA · tema comida**

«La carne llegó en el término exacto que pedimos y con un sabor espectacular.»

TEXTO LIMPIO

**carne** · **termino** · exacto · **pedir** · sabor · espectacular

**NEGATIVA · tema comida**

«La carne estaba dura y pasada de término aunque la pedimos jugosa.»

TEXTO LIMPIO

**carne** · duro · **termino** · **pedir** · jugoso

Similitud coseno con TF-IDF: **0.496**

Comparten carne, pedir, termino: son vecinas más cercanas entre sí.

La positiva más parecida a la primera: **0.152**

*«Tienen opciones para todos los bolsillos sin sacrificar el sabor.»*

**El modelo ve lo que comparten, no la valoración.** El vecino más cercano tiene la polaridad opuesta en el 64 % de las reseñas.

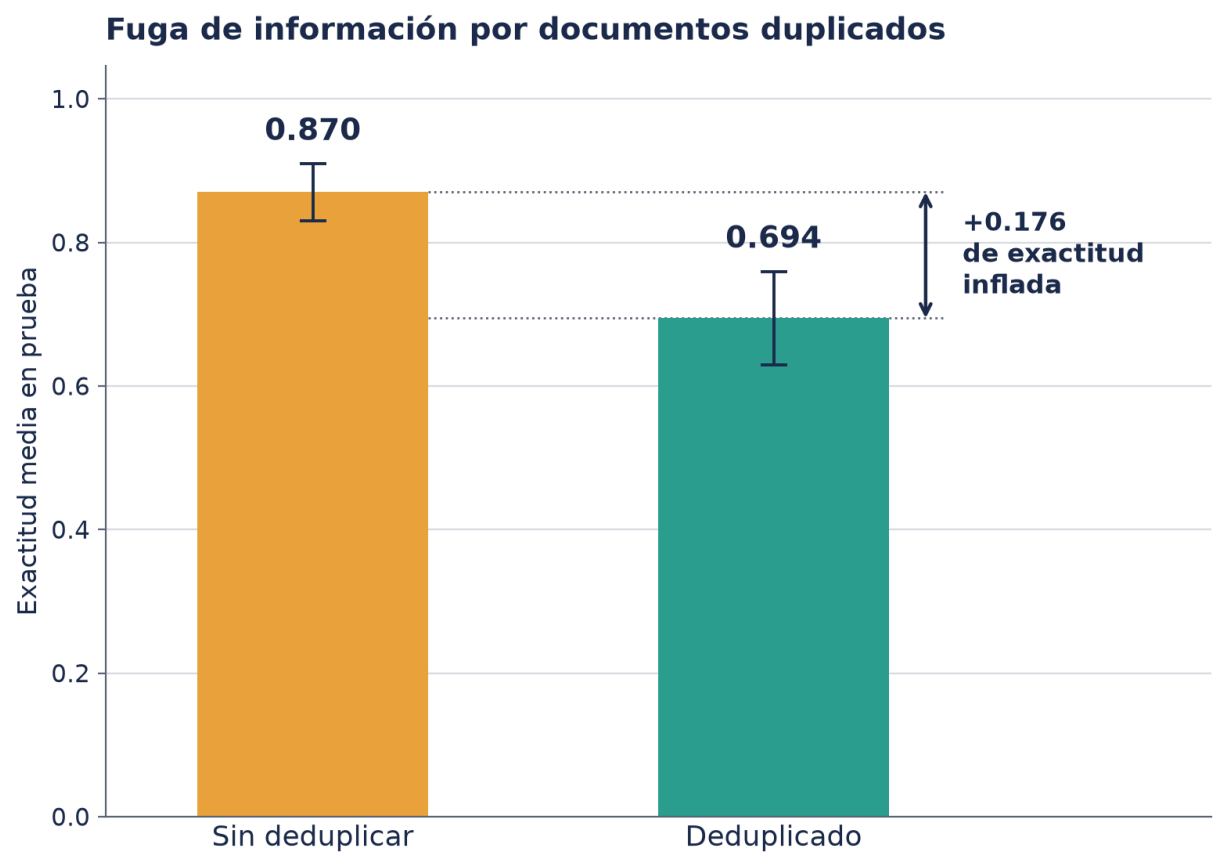
BLOQUE 3

# Fuga de información por documentos duplicados

Cuando el modelo ya vio la respuesta, la exactitud sube sin que el modelo mejore

Parte 3 del notebook · ~20 min

# 80 copias entre 200 documentos inflan la exactitud en +0.176




80 de los 200 documentos (40 %) eran copias de otros documentos del corpus.
Barras de error: ±1 desviación estándar entre particiones.

**0.870**

exactitud media sin deduplicar

**0.694**

exactitud media deduplicado

Mismo modelo, misma representación, mismas particiones. Todo el aumento es memorización medida como si fuera desempeño.

# Un duplicado visto de cerca

«Llamé tres veces para confirmar la reserva y nunca contestaron.»

Tema real: servicio · aparece 3 veces en el corpus contaminado

**ENTRENAMIENTO · 140 RESEÑAS**



**una copia de la reseña**

**PRUEBA · 60 RESEÑAS**



**la reseña que se evalúa**

**CON LA COPIA EN ENTRENAMIENTO**

Predicción: **servicio** (39 %) · **correcta**

**MISMA PARTICIÓN, SIN ESA COPIA (139 RESEÑAS)**

Predicción: **comida** (28 %) · **incorrecta**

servicio baja a 21 %

**El acierto venía de la copia, no de lo aprendido.** Repetido en muchas reseñas de prueba, eso produce el +0.176 de la diapositiva anterior.

# Tres fugas frecuentes y su control

| | | |
|---|---|---|
| **Duplicados exactos** | La misma reseña publicada dos veces. | Deduplicar antes de separar: df.drop_duplicates(subset="texto"). |
| **Casi duplicados** | La misma reseña con otro signo de puntuación o una letra distinta. | Detectarlos por similitud de caracteres: verificar_corpus.py, umbral 0.95. |
| **Vectorizador ajustado con todo** | Vocabulario e IDF calculados con los documentos de prueba. | Poner el vectorizador dentro del Pipeline, como en evaluar(). |

BLOQUE 4

# Taller de entregables del Módulo 2

Del experimento al informe de la Actividad 2 y a la presentación de la Actividad 3

Parte 4 del notebook · ~35 min

# Actividad 2 · Informe PDF

Los cuatro campos de la ficha son los cuatro criterios de la rúbrica

| Criterio | Puntos | Qué debe aparecer |
|---|---|---|
| Implementación de BoW y TF-IDF | 1.5 | Herramientas, texto de entrada, dimensiones y dispersión de cada matriz. |
| Aplicación en la tarea propuesta | 1.5 | Misma tarea, mismas particiones, mismo modelo; vectorizador dentro del Pipeline. |
| Análisis comparativo de resultados | 1.0 | Media, desviación, rango y diferencia; figura de variación entre particiones. |
| Argumentación y conclusiones | 1.0 | Cuándo conviene cada una, con lo que midieron y no con lo que suele pasar. |

**Validación del notebook:** el campo de análisis debe citar cifras; si no, la celda no pasa.

# Actividad 3 · Presentación de la arquitectura

Máximo 8 diapositivas; la plantilla trae una pregunta guía en cada una

**1**

**Problema y corpus**

**2**

**Arquitectura general**

**3**

**Preprocesamiento**

**4**

**Representación**

**5**

**Modelo**

**6**

**Evaluación**

**7**

**Riesgos**

**8**

**Conclusión**

| Criterio de la rúbrica | Pts. |
|---|---|
| Diseño de la arquitectura | 1.5 |
| Justificación de cada componente | 1.5 |
| Coherencia entre representación y modelo | 1.0 |
| Presentación | 1.0 |

# Antes de escribir: verifiquen su corpus

Un script que corre el experimento de la Parte 2 sobre cualquier CSV con texto y etiqueta

```
!python verificar_corpus.py mi_corpus.csv --texto texto --etiqueta etiqueta
```

**DOCUMENTOS Y CLASES**

Número de documentos, de clases y balance entre ellas.

**DUPLICADOS**

Exactos y casi exactos (similitud de caracteres > 0.95).

**MATRICES**

Dimensionalidad y dispersión con BoW y con TF-IDF.

**EXACTITUD**

Media, desviación y victorias en 30 particiones estratificadas.

Advierte si hay duplicados sin eliminar y si la diferencia entre medias es menor que la variación entre particiones.

# Lo que nos llevamos

- El orden de las etapas de limpieza cambia lo que ve el lematizador.
- Comparar representaciones exige las mismas particiones, el mismo modelo y muchas particiones.
- Las ventajas de una representación dependen del preprocesamiento y de la tarea.
- Los duplicados y el vectorizador ajustado antes de separar inflan la exactitud.

ENTREGA DEL MÓDULO 2

**Domingo 27 de septiembre**

Actividades 1, 2 y 3

PRÓXIMA SESIÓN

**Martes 22 de septiembre**

Análisis de sentimientos

Antes de cerrar Colab: todas las celdas ejecutadas, reflexiones 2, 3 y 4 escritas, notebook descargado y subido.