FUNDAMENTOS DE PROCESAMIENTO DE LENGUAJE NATURAL

Sesión 6

Clasificación básica de texto

Del diseño en papel a un clasificador que se puede medir

Módulo 3 · Arranque de la Actividad 1
Universidad de La Sabana · 29 de septiembre de 2026



Del diseño al código

Lo que ya hicieron, lo que hacemos hoy y lo que entregan

Módulo 2 · Actividad 3

Arquitectura de clasificación en papel

Entregada el 27 de septiembre

→

Hoy · Sesión 6

Etiquetar, entrenar, evaluar y analizar

Reto en parejas

→

Módulo 3 · Actividad 1

Clasificador: notebook + reporte de 2 páginas

20 % · entrega el 1 de noviembre

La pregunta del día: ¿cómo sabemos que el clasificador es bueno y no solo que lo parece?

Agenda

Martes 3:00 a 6:00 p. m.

3:00	**Apertura**	Del diseño a la implementación y rúbrica de la actividad
3:15	**Concepto**	Naive Bayes a mano y repaso de Regresión Logística
3:45	**Reto · Partes 1 y 2**	Definir clases, etiquetar por separado y medir el acuerdo
4:20	**Pausa**	
4:30	**Reto · Parte 3**	Duplicados, línea base, Naive Bayes y Regresión Logística
5:20	**Reto · Parte 4**	Términos por clase, errores y validación cruzada
5:45	**Cierre**	Estructura del reporte y adelanto de la Sesión 7

La rúbrica que vamos a practicar

Actividad 1 del Módulo 3 · Clasificador de texto · 5.0 puntos

1.5

Implementación técnica

Modelo correcto, partición entrenamiento/prueba, ejecución sin errores

Reto: Parte 3

1.5

Uso de la representación

BoW o TF-IDF bien integrado con el modelo, y justificado

Reto: Partes 3 y 4

1.0

Evaluación del desempeño

Accuracy, precisión, recall o F1, con interpretación

Reto: Parte 3

1.0

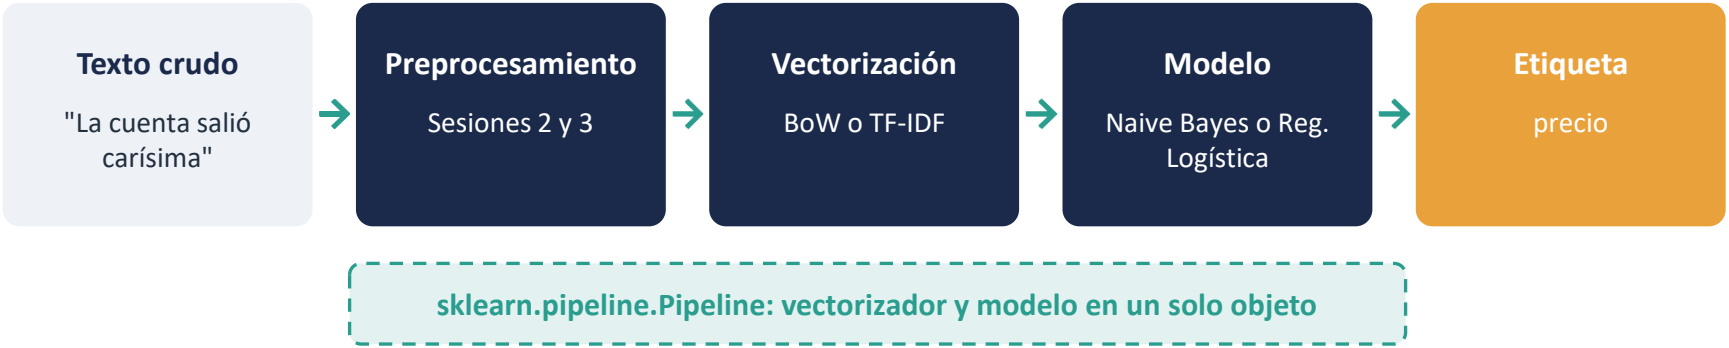
Análisis e interpretación

Limitaciones y mejoras posibles del modelo

Reto: Parte 4

Clasificación supervisada de texto

Aprender una función de texto a etiqueta a partir de ejemplos etiquetados



- El vocabulario y los pesos IDF se aprenden solo con el conjunto de entrenamiento.
- El mismo objeto predice textos nuevos, sin repetir pasos a mano.
- Si usan su pipeline_nlp(): devuelve una lista de tokens y el vectorizador espera un string por documento. Únanlos con espacios antes de vectorizar.

Naive Bayes: contar palabras por clase

Un modelo generativo que se puede calcular a mano

$$\hat{c} = \text{argmax}_c \; P(c) \cdot \prod P(w|c)$$

$$P(w|c) = \frac{\text{count}(w,c) + 1}{N_c + |V|}$$

P(c)	Proporción de documentos de la clase: el prior.
P(w | c)	Qué tan frecuente es la palabra dentro de la clase.
+1	Suavizado de Laplace: sin él, una palabra ausente en la clase anula todo el producto.
Naive	Supone que las palabras son independientes dada la clase. Es falso, y aun así funciona.

En scikit-learn

`MultinomialNB(alpha=1)`

- alpha=1 es exactamente el suavizado de Laplace.
- Rápido y estable con pocos datos.
- Pensado para conteos (BoW). Con TF-IDF también funciona, pero cambia qué significa "contar".

Naive Bayes a mano

Seis documentos, dos clases, un documento ambiguo

comida	servicio
sopa fría sin sabor	mesero lento
carne deliciosa	mesero grosero lento
sopa deliciosa caliente	mesera amable
N = 9 palabras	**N = 7 palabras**

Documento nuevo *"sopa deliciosa pero mesero lento"*

|V| = 12 · "pero" no está en el vocabulario y se ignora

comida

$$\tfrac{1}{2} \cdot (3/21)^2 \cdot (1/21)^2 = 2.31 \times 10^{-5}$$

P(c) sopa, deliciosa mesero, lento

servicio

$$\tfrac{1}{2} \cdot (1/19)^2 \cdot (3/19)^2 = 3.45 \times 10^{-5}$$

P(c) sopa, deliciosa mesero, lento

0.401

P(comida | doc)

0.599

P(servicio | doc)

scikit-learn con MultinomialNB(alpha=1) da exactamente los mismos valores.

Naive Bayes y Regresión Logística

Ya conocen la Regresión Logística: con texto, cada palabra es una variable

Naive Bayes

- Generativo: modela cómo se ve el texto de cada clase.
- Se entrena contando. Sin iteraciones.
- Funciona bien con muy pocos datos.
- Supone independencia entre palabras.

Regresión Logística

- Discriminativo: aprende directamente la frontera entre clases.
- Un coeficiente por palabra y por clase: se puede inspeccionar.
- Necesita regularización. Con desbalance, class_weight="balanced".
- Suele ganar cuando hay más datos.

La guía de la actividad permite cualquiera de los dos. Lo que se evalúa es que justifiquen la elección con evidencia.

Sin etiquetas no hay clasificación

Los corpus del Módulo 1 no tienen etiquetas. Dos rutas.

Ruta A · Recomendada

Etiquetar su propio corpus

- Definan 2 o 3 clases y una guía de anotación.
- Cada integrante etiqueta por separado los mismos 40 documentos.
- Midan el acuerdo, corrijan la guía y completen al menos 150 documentos.

Ruta B · Alternativa

Dataset público etiquetado

- Solo si su corpus no admite una tarea razonable.
- Sugerido: mteb/SpanishNewsClassification (2.048 noticias, 12 categorías, licencia MIT).
- Elijan 3 o 4 categorías y justifiquen la decisión en el reporte.

Etiquetar también es difícil

Si dos personas no coinciden, ningún modelo puede ser mejor que ese acuerdo

Una buena guía de anotación dice

Qué entra
servicio: trato, esperas, errores en el pedido

Qué no entra
servicio: montos de la cuenta (eso es precio)

Casos mixtos
Qué hacer cuando un texto habla de dos temas

Kappa de Cohen

$$\kappa = (p_o - p_e) / (1 - p_e)$$

- p_o: proporción de documentos en que coinciden.
- p_e: coincidencia esperada por azar, Σ p_A(c) · p_B(c).
- Corrige lo que el porcentaje simple exagera.

0.41–0.60	0.61–0.80	> 0.80
moderado	sustancial	casi perfecto

Landis y Koch (1977)

El corpus de los ejemplos

Sintético: generado con plantillas para que cada fenómeno aparezca con certeza

Cómo se arma una reseña

Contexto (opcional)	*"Fuimos en familia."*
Valoración del tema	*"La cuenta salió carísima."*
Segundo tema (35 %)	*"El mesero fue muy amable."*

Etiqueta: **precio**

300 reseñas, 240 únicas. Semilla fija: generate_synthetic_corpus.py reproduce el CSV exacto.

Sembrado a propósito

Desbalance 146 / 58 / 36	→ paradoja del accuracy
Reseñas con dos temas	→ desacuerdo entre anotadores
10 etiquetas cambiadas	→ errores de anotación
60 duplicados (RT, MAYÚSCULAS, !!)	→ fuga de datos

No tiene sarcasmo, errores de ortografía, jerga ni textos largos. Con su corpus esperen métricas más bajas.

Lo que muestra el acuerdo

Muestra de 40 reseñas del corpus ilustrativo, dos anotadores

comida servicio precio

Cada ficha es una reseña: mitad izquierda = A, mitad derecha = B



9 desacuerdos

0.775 coincidencia simple

0.649 kappa: sustancial

8 de 9: la reseña habla de dos temas

"El mesero nos recomendó muy bien. La cuenta es muy razonable."

A: precio · B: servicio

1 de 9: la etiqueta del corpus estaba mal

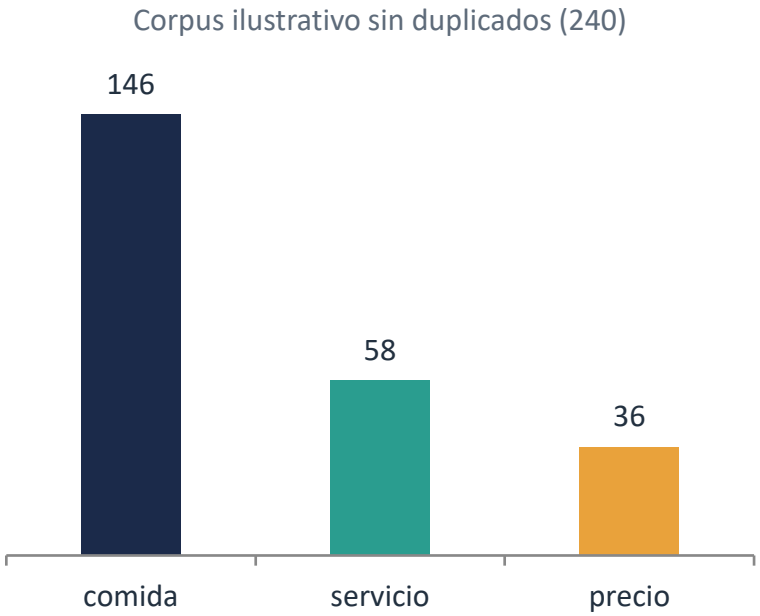
"La pizza llegó en su punto."

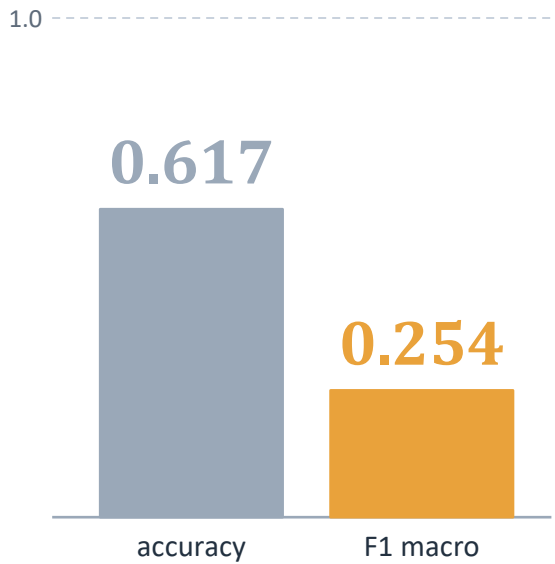
Corpus: servicio · B: comida

Si dos personas coinciden en el 77 % de los casos, un accuracy del 95 % sería sospechoso.

Trampa 1: la paradoja del accuracy

Un modelo que nunca lee el texto: siempre responde la clase más frecuente





F1 = 0
en servicio y en precio.

El F1 macro promedia las clases con el mismo peso.

Toda cifra que reporten se compara con esta línea base.

Trampa 2: el modelo que recuerda

Reenvíos y copias casi idénticas a ambos lados de la partición

8

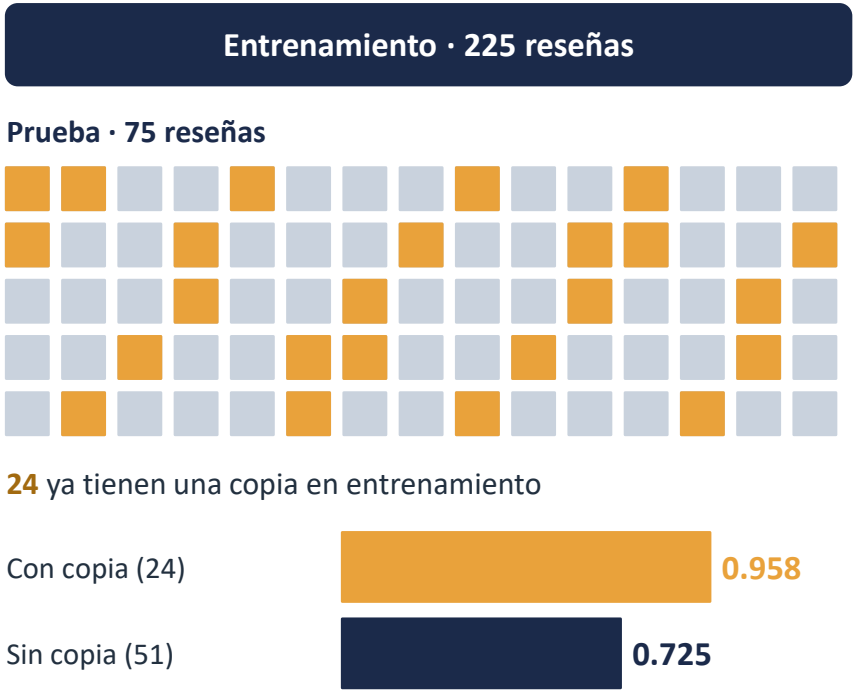
duplicados exactos con drop_duplicates()

60

duplicados tras normalizar (RT, mayúsculas, signos)

```
"Cobraron el servicio sin preguntar. La pizza tenía una sazón casera."
"COBRARON EL SERVICIO SIN PREGUNTAR. LA PIZZA TENÍA UNA SAZÓN CASERA."
```

Se deduplica con normalización y antes de particionar.



Primeros resultados: una partición

TF-IDF, sin duplicados, 180 para entrenar y 60 para probar

Recall por clase	Naive Bayes	Reg. Logística
comida (37)	1.000	1.000
servicio (14)	0.571	**0.357**
precio (9)	**0.333**	**0.333**
F1 macro	**0.696**	**0.610**

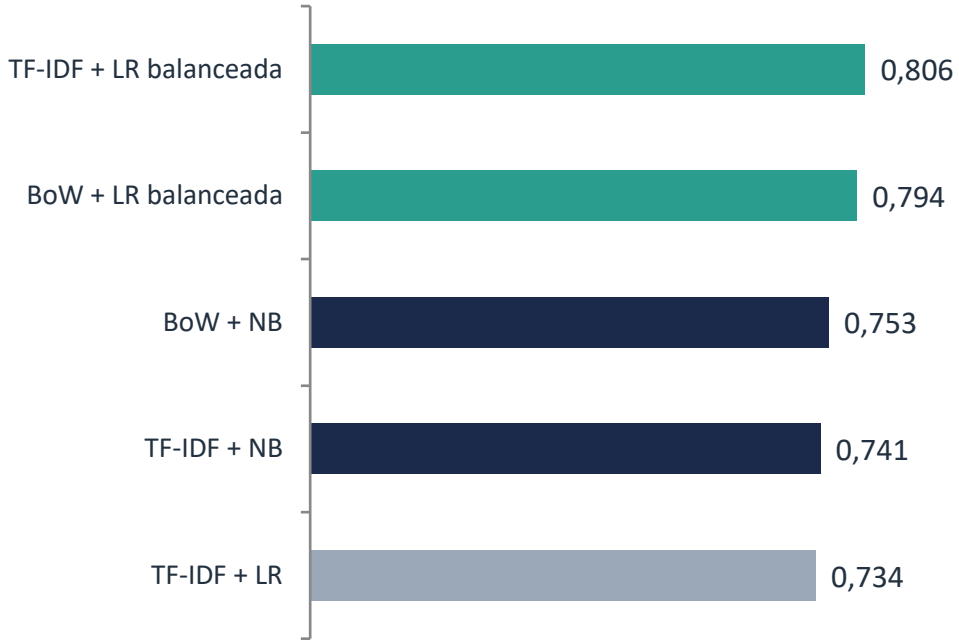
Línea base: F1 macro 0.254

Diagnóstico

- Ante la duda, el modelo responde comida: recall 1.000.
- precio: solo 27 ejemplos para entrenar, y muchos mezclan precio con comida.
- Cuando dice precio, casi siempre acierta. Se atreve muy poco.
- ¿Qué modelo es mejor? Con 60 documentos de prueba no se puede afirmar todavía.

Tres mejoras, medidas con validación cruzada

F1 macro, media de 5 particiones estratificadas



Balancear clases

class_weight="balanced" lleva la Reg. Logística de 0.734 a 0.806.

BoW o TF-IDF

No hay ganador fijo: con NB gana BoW; con LR, TF-IDF por un punto.

Validación cruzada

La desviación es de 4 a 8 puntos. Reporten media y desviación.

¿Qué aprendió el modelo?

Coeficientes más altos por clase (Regresión Logística, TF-IDF)

comida	precio	servicio
estaba	precio	fue
tenía	del	administrador
sabor	está	nos
churrasco	bebidas	cajero
aceite	domicilio	muy

Resaltados: palabras que no describen el tema. Son huella de las plantillas del corpus sintético: atajos que fallarían con reseñas reales.

Tres tipos de error

Del modelo

"El domiciliario fue muy amable..." → comida

De la etiqueta

"La carta es económica." marcada como servicio

Texto ambiguo

Reseñas que mezclan precio y servicio

La evaluación no puede ser más confiable que las etiquetas.

Glosario de la sesión · Tarea y datos

Clasificación supervisada
Aprender, a partir de textos ya etiquetados, una función que asigna una clase a un texto nuevo.

Corpus sintético
Textos generados por un programa, no escritos por personas. Sirve para controlar qué fenómenos aparecen.

Guía de anotación
Reglas escritas que dicen qué entra y qué no entra en cada clase, y qué hacer con los casos mixtos.

Acuerdo entre anotadores
Qué tanto coinciden dos personas que etiquetan los mismos textos de forma independiente.

Kappa de Cohen
Acuerdo corregido por el azar: $\kappa = (p_o - p_e) / (1 - p_e)$. Vale 1 si el acuerdo es perfecto y 0 si es el esperable por azar.

Desbalance de clases
Una clase tiene muchos más ejemplos que las demás. Infla el accuracy de cualquier modelo que la favorezca.

Duplicado cercano
Dos textos iguales salvo diferencias superficiales: mayúsculas, un "RT" al inicio o signos extra.

Fuga de datos
Información del conjunto de prueba que llega al entrenamiento. Hace que las métricas parezcan mejores de lo que son.

Partición estratificada
División entrenamiento/prueba que conserva en ambos lados la proporción de cada clase.

Validación cruzada
Entrenar y evaluar en k particiones distintas y promediar. Se reporta la media y la desviación.

Pipeline
Objeto de scikit-learn que encadena vectorizador y modelo, y aprende todo solo con el conjunto de entrenamiento.

Atajo
Palabra que se asocia con una clase en un corpus sin describirla, como "estaba" o "fue". Falla al cambiar de corpus.

Glosario de la sesión · Modelos y métricas

Bolsa de palabras (BoW)
Vector con el número de veces que aparece cada palabra del vocabulario en el documento.

TF-IDF
El conteo de cada palabra ponderado por su rareza en el corpus. Baja el peso de las palabras muy comunes.

Naive Bayes multinomial
Multiplica P(c) por P(w|c) de cada palabra y elige la clase con el producto más alto. Supone palabras independientes.

Prior P(c)
Proporción de documentos de la clase c en el conjunto de entrenamiento.

Suavizado de Laplace
Sumar α = 1 a cada conteo para que una palabra nunca vista en una clase no anule su probabilidad.

Regresión Logística
Modelo discriminativo que aprende un peso por palabra y por clase. Los pesos se pueden inspeccionar.

class_weight="balanced"
Hace que los errores en clases pequeñas pesen más, en proporción inversa a su frecuencia.

Línea base
Modelo trivial de referencia. Aquí: responder siempre la clase más frecuente sin leer el texto.

Accuracy
Proporción de predicciones correctas sobre el total.

Precisión y recall
Precisión: de lo que el modelo llamó c, cuánto era c. Recall: de lo que era c, cuánto encontró.

F1 y F1 macro
F1: media armónica de precisión y recall. F1 macro: promedio del F1 de cada clase, todas con el mismo peso.

Matriz de confusión
Tabla de clases reales contra clases predichas. Muestra hacia dónde se van los errores.

Para la Actividad 1 del Módulo 3

Notebook + reporte técnico de 2 páginas · entrega el 1 de noviembre

Etiquetas	Guía corregida y al menos 150 documentos, con el kappa de la muestra de 40.
Limpieza	Duplicados normalizados eliminados antes de particionar.
Evaluación	Línea base, F1 macro y validación cruzada con media y desviación.
Análisis	Términos por clase, errores clasificados por tipo y dos mejoras concretas.



Sesión 7 · 13 de octubre

Análisis de sentimientos

¿Dónde termina lo neutral? El mismo problema de etiquetas, ahora con opiniones.

La función entrenar_y_evaluar() de la Parte 5 del reto ya hace la mayor parte. Aplíquenla a su corpus apenas terminen de etiquetar.