Módulo 3 · Sesión 7 · 20 de octubre de 2026

Afinar el clasificador y medir la opinión

César Augusto Vega Fernández

Fundamentos de Procesamiento de Lenguaje Natural

Preprocesamiento como experimento · Curva de aprendizaje · Léxico de sentimientos · Negación · Actividad 2

Dónde estamos

Sesión 7 de 8 · las dos actividades del Módulo 3 se entregan el 8 de noviembre

30 %

Módulo 1

Preparación y gestión de texto

21 jul · 4 ago · 18 ago

Entregado el 23 de agosto

30 %

Módulo 2

Representaciones y diseño de modelos básicos

1 sep · 15 sep · 29 sep

Entregado el 27 de septiembre

40 %

Módulo 3

Resolución de problemas introductorios en NLP

20 oct · 3 nov

Entrega: 8 de noviembre

Actividad 1: clasificador (notebook + reporte) · Actividad 2: sentimientos (video). 20 % cada una.

Plan de la sesión

Dos bloques · cada uno con su concepto y su parte del reto

00:00	Lo que resolvimos en la sesión 6 y lo que quedó abierto
00:10	Bloque A · ¿sirve el preprocesamiento? ¿cuántas etiquetas necesito?
00:15	Reto · Partes 1 y 2 · al volver, los resultados
01:05	Pausa
01:15	Bloque B · sentimientos y demo en vivo de la negación
01:30	Reto · Partes 3 a 8 · al volver, la tabla de resultados
02:40	Actividad 2: rúbrica y guion del video
02:55	Cierre y tarea para la sesión 8

Lo que ya resolvimos en la sesión 6

Hoy no lo repetimos: lo usamos

Ya lo tienen

- ✓ Guía de anotación y kappa de Cohen
- ✓ Duplicados y fuga entre entrenamiento y prueba
- ✓ Línea base y paradoja del accuracy
- ✓ Naive Bayes a mano y Regresión Logística
- ✓ class_weight, BoW frente a TF-IDF, validación cruzada
- ✓ Coeficientes por clase y análisis de errores

Quedó abierto · Actividad 1

¿Sirve el preprocesamiento del Módulo 1?
En la sesión 6 vieron fue, nos y estaba entre los términos con más peso.

¿Cuántas etiquetas necesito?
Etiquetar cuesta horas. ¿Cuándo es suficiente?

Nuevo · Actividad 2

¿Cómo se mide la opinión de un texto y por qué la negación lo complica todo?

Bloque A usa el mismo corpus de la sesión 6: 240 reseñas sin duplicados, tres temas.

Recorderis · del texto a los números

Módulos 1 y 2 · lo que hoy vamos a medir en el Bloque A

término	qué hace	ejemplo del curso
Stopwords	Quita las palabras más frecuentes del idioma: artículos, preposiciones… y también "no"	"La sopa no estaba rica" → sopa rica
Stemming	Recorta cada palabra a una raíz para juntar sus variantes	meseros → meser · amables → amabl
n-gramas	Además de palabras sueltas, cuenta pares o tríos de palabras seguidas	"no estaba rica" → no estaba · estaba rica
BoW y TF-IDF	BoW cuenta cuántas veces sale cada palabra; TF-IDF le baja el peso a las que salen en casi todos los textos	"la" pesa poco en TF-IDF; "ajiaco" pesa más
Frecuencia mínima	Descarta las palabras que aparecen en muy pocos textos (min_df)	min_df=2: solo palabras que salen en 2 reseñas o más
Similitud coseno	Qué tan parecidos son dos vectores: 1 es igual, 0 es nada en común	mesero y camarero con BoW: 0.000 (sesión 4)

Si alguno no les suena, pregunten ahora: hoy los usamos sin volver a explicarlos.

Recorderis · clasificar y evaluar

Sesión 6 · lo que hoy usamos sin volver a explicarlo

término	qué hace	ejemplo del curso
Pipeline y Regresión Logística	Vectorizador y clasificador en un solo paso; la regresión aprende un peso por palabra y por clase	"fue", "nos" y "estaba" pesaban para servicio
Validación cruzada	Se entrena 5 veces, cada vez probando con un quinto distinto; se reporta media ± desviación	F1 macro 0.806 ± 0.066
F1 macro	Promedia el F1 de cada clase con el mismo peso: la clase pequeña cuenta igual que la grande	comida 146 · servicio 58 · precio 36 reseñas
Línea base	El modelo que nunca lee: siempre responde la clase más frecuente. Todo resultado se compara con ella	accuracy 0.617, pero F1 macro 0.254
Duplicados y fuga	Si la misma reseña queda en entrenamiento y en prueba, la métrica se infla. Se quitan antes de partir	300 reseñas → 240 únicas
Kappa de Cohen	Cuánto coinciden dos personas al etiquetar, descontando el azar	0.775 de coincidencia · κ = 0.649

Si alguno no les suena, pregunten ahora: hoy los usamos sin volver a explicarlos.

Reto · Partes 1 y 2

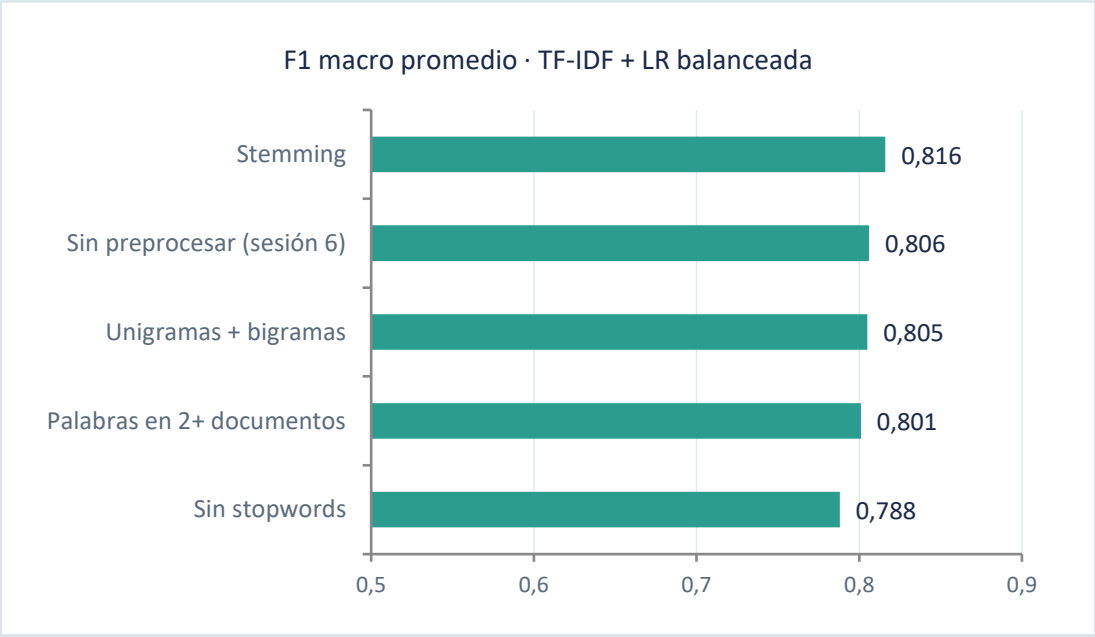
40 minutos · en parejas · en Colab · al volver vemos lo que les dio

Parte 1	**Un modelo, cinco versiones del texto**	Bloque A · ¿sirve el preprocesamiento?	**25 min**
Parte 2	**Curva de aprendizaje**	Bloque A · ¿cuántas etiquetas necesito?	**15 min**

Archivos: resenas_restaurantes_etiquetadas.csv (sesión 6) y resenas_polaridad.csv (nuevo).

¿Sirve el preprocesamiento del Módulo 1?

Lo que les dio la Parte 1 · mismo corpus y modelo, una sola cosa cambia · F1 macro, 5 pliegues



±0.066

desviación entre pliegues de la referencia.
Todas las diferencias son menores.

El vocabulario sí cambia

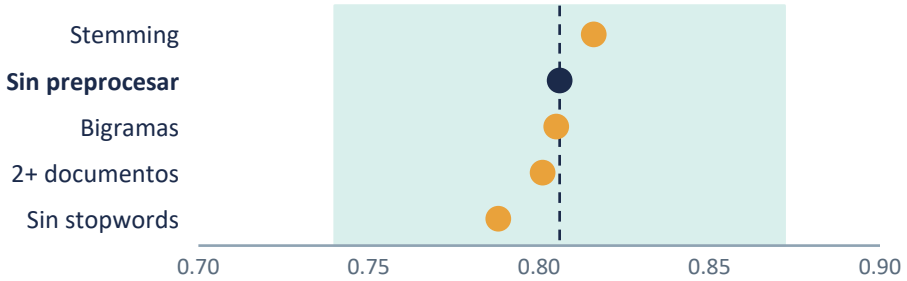
261 términos sin preprocesar
213 con stemming · 217 sin stopwords
964 con bigramas

Menos columnas no significa mejor modelo. Quitar stopwords incluso baja un poco: nos y fue dan pistas de servicio.

¿La diferencia es real?

Lo que les dio la Parte 1 · una media sola no basta: hay que compararla con cuánto varía entre pliegues

F1 macro de la referencia: 0.806 ± 0.066



Banda verde: una desviación alrededor de la referencia. Todos los puntos caen dentro.

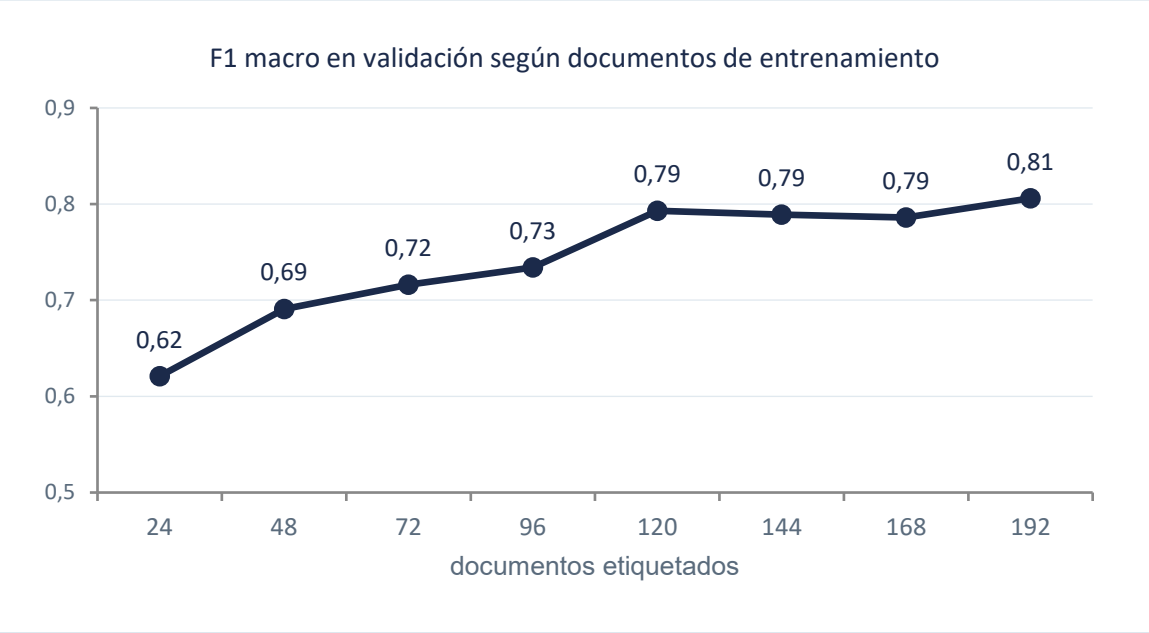
Regla práctica

Si la diferencia entre dos configuraciones es menor que una desviación, no hay evidencia de que una sea mejor. Se elige la más simple.

Cómo escribirlo en el reporte: *"Probamos stopwords, stemming, bigramas y frecuencia mínima. Ninguna mejoró el F1 macro más allá de la variación entre pliegues (±0.07), así que usamos TF-IDF sin preprocesar."*

¿Cuántas etiquetas necesito?

Lo que les dio la Parte 2 · curva de aprendizaje: el mismo pipeline con cada vez más documentos



24 → 120

+0.17 de F1

La curva sube rápido: cada etiqueta cuenta.

120 → 192

+0.01 de F1

Se aplana: más etiquetas casi no ayudan.

Con 150 a 200 textos etiquetados quedan en la zona plana, si su tarea tiene pocas clases y etiquetas claras.

Sentimientos: la misma máquina, otra pregunta

Actividad 2 · clasificar cada texto según su polaridad y evaluar sus limitaciones

Léxico

Una lista de palabras positivas y otra de negativas. Se cuentan y gana la que más tenga.

- No necesita datos para entrenar
- Transparente: se explica palabra por palabra
- Alguien tiene que escribir las listas y las reglas

Supervisado

El clasificador de la sesión 6, con etiquetas de polaridad en lugar de temas.

- Aprende de ejemplos etiquetados
- Encuentra pistas que nadie escribió
- Solo ve lo que la representación le muestra

Corpus del reto: 400 reseñas positivas o negativas. Un tercio tiene negación y una de cada cinco tiene un “pero”.

Cuatro frases sobre la misma sopa

Demo en vivo · un léxico de dos palabras: rica suma +1 y mal suma −1

frase	real	léxico	léxico + regla
`La sopa estaba rica.`	positivo	positivo	positivo
`La sopa no estaba rica.`	negativo	**positivo**	negativo
`La sopa estaba mal.`	negativo	negativo	negativo
`La sopa no estaba mal.`	positivo	**negativo**	positivo

La regla

Después de no, nunca, ni, nada o tampoco, se invierte la polaridad de las palabras siguientes hasta la puntuación.

"No solo estaba rica, estaba deliciosa" → la regla falla.

Sin la regla, el léxico acierta la mitad. Con una regla corta, las cuatro.

Para la bolsa de palabras, “no” es una palabra más

Similitud coseno entre “La sopa estaba rica” y “La sopa no estaba rica”

0.894

Bolsa de palabras

Las dos frases solo se diferencian en la columna no. Para el modelo son casi la misma opinión.

1.000

Sin stopwords (Módulo 1)

NLTK elimina no. Las dos frases quedan como sopa rica: el mismo vector exacto.

0.447

Negación marcada

rica y NEG_rica son columnas distintas. El modelo puede darles pesos opuestos.

`la sopa no estaba rica` → **`la sopa no NEG_estaba NEG_rica`**

Reto · Partes 3 a 8

Una hora · en parejas · al volver vemos la tabla de resultados

Partes 3–4	**Léxico a mano y regla de negación**	Bloque B · evaluación por grupos	**25 min**
Partes 5–7	**Supervisado, stopwords y negación marcada**	Bloque B · la tabla completa de resultados	**25 min**
Parte 8	**Matriz de confusión y errores**	Bloque B · la limitación para el video	**10 min**

Archivos: resenas_restaurantes_etiquetadas.csv (sesión 6) y resenas_polaridad.csv (nuevo).

Resultados en 400 reseñas

Lo que les dio el reto · accuracy por grupo, con validación cruzada de 5 pliegues en los supervisados

método	todas	sin negación ni contraste	con negación	con contraste
Léxico inicial	0.465	0.761	0.045	0.237
Léxico + regla de negación	**0.825**	**0.972**	**0.788**	**0.338**
TF-IDF + LR	0.660	0.723	0.561	0.625
TF-IDF sin stopwords + LR	0.627	0.704	0.500	0.637
TF-IDF 1 a 3-gramas + LR	0.690	0.732	0.636	0.637
TF-IDF + negación marcada + LR	**0.812**	**0.854**	**0.788**	**0.675**

En el léxico, una reseña sin decisión (sin palabras del léxico o con empate) cuenta como error: 25 % en el léxico inicial, 13 % con la regla.

En estas 400 reseñas, el léxico con una regla escrita a mano empata o supera al supervisado. En la sesión 8 lo probamos fuera de ellas. El supervisado solo gana cuando le marcamos la negación.

La trampa de las stopwords

Lo que les dio la Parte 6 · en el Bloque A quitarlas no cambió nada; aquí destruye la información

Lista de stopwords de NLTK en español

no	nada	ni	sin
pero	muy	nunca	tampoco

Ámbar: incluidas en la lista. Las elimina el pipeline del Módulo 1.

```
el mesero no fue grosero
→ mesero grosero
```

0.561

TF-IDF + LR
grupo con negación

0.500

sin stopwords
es adivinar

Para la Actividad 2

No usen la lista tal cual. Saquen de ella los negadores y pero, o marquen la negación antes de vectorizar.

Un mismo paso de preprocesamiento puede ser inofensivo para una tarea y destructivo para otra.

¿Por qué no bastan los n-gramas?

Lo que les dio la Parte 7 · los dos intentan “ver” el no; solo uno lo pega a la palabra que importa

Bigramas

`no estaba · estaba rica`

El “no” casi nunca está pegado a la palabra de opinión. no estaba no dice nada de la sopa.

0.636

accuracy en el grupo con negación (con 1 a 3-gramas)

Negación marcada

`NEG_estaba · NEG_rica`

NEG_rica es una sola columna que aparece en muchas reseñas. El modelo la aprende fácil.

0.788

accuracy en el grupo con negación

Los trigramas sí capturan no estaba rica, pero cada trigrama aparece muy pocas veces en 400 reseñas.

Evaluar por grupos

Lo que les dio la Parte 8 · accuracy 0.812, F1 macro 0.811 · ¿dónde están los 75 errores?

Negación

Casi resuelto: los errores están en proporción.

33 %

del corpus

37 %

de los errores

Contraste

Sobrerrepresentado: el límite de todos los métodos de hoy.

20 %

del corpus

35 %

de los errores

El caso abierto

“El menú del día fue razonable, pero el ajiaco estaba seco.”

Una opinión positiva y una negativa. El léxico suma cero. El modelo las pesa igual. Lo que viene después de “pero” debería pesar más.

La rúbrica pide matriz de confusión. La evaluación por grupos es la que convierte las métricas en una limitación concreta para el video.

Actividad 2 del Módulo 3 · rúbrica

Análisis de sentimientos · video de 5 minutos · 20 % · entrega el 8 de noviembre

1.5	**Preparación e implementación del modelo** Datos bien preprocesados y estructurados; modelo implementado correctamente.	→ *Partes 3 a 7*
1.5	**Aplicación al conjunto de reseñas** Predicciones claras y resultados organizados de forma estructurada.	→ *Partes 7 y 8*
1.0	**Evaluación cuantitativa del desempeño** Accuracy, F1 y matriz de confusión, con interpretación adecuada.	→ *Parte 8*
1.0	**Video** A tiempo, con los requisitos, atractivo, concreto y conciso.	→ *Parte 9.2*

Total 5.0. Un video que pasa de 5 minutos no cumple los requisitos: pierde puntos en el último criterio.

Cómo armar el video de 5 minutos

Un bloque por criterio · el tiempo es parte de la nota



0:00–0:45	**El problema y los datos**	Qué opinan los textos, cómo etiquetaron, cuántos por clase
0:45–2:00	**El modelo**	Léxico, supervisado o ambos. Qué hicieron con la negación y por qué
2:00–3:15	**Resultados**	Predicciones organizadas, ejemplos acertados y fallados
3:15–4:30	**Métricas**	Accuracy, F1, matriz de confusión y resultados por grupo
4:30–5:00	**Limitaciones**	Qué no resuelve su modelo, con un ejemplo concreto

La frase de limitación sale de la Parte 8: un ejemplo real de su corpus vale más que una métrica más.

Para llevarse de hoy

01 El preprocesamiento es una hipótesis: se mide, y si no supera la variación entre pliegues, se elige lo más simple.

02 Para la bolsa de palabras el orden no existe. La negación hay que hacérsela visible: con una regla o marcándola.

03 Un mismo paso puede ser inofensivo para temas y destructivo para opiniones. Las stopwords se revisan por tarea.

Próxima sesión · 3 de noviembre

- Traer su muestra etiquetada por tema y por polaridad
- Sesión 8: su modelo frente a un modelo de lenguaje, el contraste y la grabación del video