Módulo 3 · Sesión 8 · 3 de noviembre de 2026

Su modelo frente a un modelo de lenguaje

César Augusto Vega Fernández

Fundamentos de Procesamiento de Lenguaje Natural

El contraste · ¿De quién es el error? · Fuera del corpus · Modelo preentrenado · Reporte y video

Dónde estamos

Sesión 8 de 8 · las dos actividades del Módulo 3 se entregan el domingo 8 de noviembre

30 %

Módulo 1

Preparación y gestión de texto

Entregado el 23 de agosto

30 %

Módulo 2

Representaciones y diseño de modelos básicos

Entregado el 27 de septiembre

40 %

Módulo 3

Clasificador de texto (notebook + reporte)
Análisis de sentimientos (video)

Entrega: domingo 8 de noviembre

Hoy: cerrar el contraste, auditar los errores, comparar con un modelo preentrenado y dejar listos reporte y video.

Plan de la sesión

Cuatro preguntas para cerrar el Módulo 3

00:00	Apertura · lo que quedó abierto en la sesión 7
00:10	El contraste · la regla del "pero" en el léxico
00:20	El contraste en el supervisado · marcar o quitar texto
00:55	¿De quién es el error? · el método o la etiqueta
01:20	Pausa
01:30	Fuera del corpus · seis frases nuevas y un modelo preentrenado
02:10	¿Cuándo usar cada enfoque? · el reporte y el video
02:50	Cierre del curso

Recorderis · lo que vimos en la sesión 7

Hoy partimos de aquí: léxico, negación y evaluación por grupos

término	qué hace	ejemplo del curso
Léxico de sentimientos	Dos listas, positivas y negativas: se cuentan y gana la que más tenga. Sin palabras o con empate, queda sin decisión	"La sopa estaba rica" → +1 · positivo
Regla de negación	Después de no, nunca, ni, nada o tampoco se invierte la polaridad de las palabras siguientes, hasta la puntuación	grupo con negación: 0.045 → 0.788
Negación marcada (NEG_)	La misma idea para el supervisado: lo que va después del negador lleva el prefijo NEG_ y queda en otra columna	no NEG_estaba NEG_rica · 0.660 → 0.812
Stopwords en sentimiento	La lista de NLTK trae "no", "nada", "ni", "sin" y "pero": quitarlas borra la opinión	"el mesero no fue grosero" → mesero grosero
Evaluación por grupos	Medir la accuracy por tipo de reseña, no solo el total, para ver dónde falla el modelo	contraste: 20 % del corpus, 35 % de los errores
Curva de aprendizaje	Entrenar con cada vez más textos etiquetados para ver cuándo dejan de ayudar	24 → 120 textos: +0.17 de F1 · 120 → 192: +0.01

Si alguno no les suena, pregunten ahora: hoy los usamos sin volver a explicarlos.

Lo que quedó abierto

El mejor modelo de la sesión 7: accuracy 0.812 · ¿dónde estaban sus 75 errores?

Contraste

Sobrerrepresentado en los errores

20 %

del corpus

35 %

de los errores

La frase

“El menú del día fue razonable, pero el ajiaco estaba seco.”

Léxico: razonable +1, seco −1 → suma 0, sin decisión

Bolsa de palabras: las dos partes pesan igual

Quien lee: negativa. Lo que va después del "pero" decide.

Bloque A · cómo hacer que pese la parte que decide, primero en el léxico y después en el modelo supervisado.

La regla del "pero"

Después de "pero", cada palabra vale el doble hasta el siguiente punto · ¿cuánto sube?

La frase: "El menú del día fue razonable, pero el ajiaco estaba seco."

Sin la regla: razonable +1, seco −1 → 0, sin decisión.

Con la regla: razonable +1, seco −1 × 2 → −1, negativa.

En el supervisado, dos caminos: marcar con POST_ lo que va después del "pero", o borrar lo que va antes.

Cuándo falla: "Muy rico todo, pero el parqueadero es pequeño." La queja de después del "pero" es un detalle; la reseña es positiva.

Grupo con contraste

0.338 → ?

Predigan: ¿hasta dónde sube con la regla? Y en el supervisado, hoy en 0.812: ¿POST_ lo sube o lo baja?

En este corpus la parte que decide siempre va después del "pero". En el suyo hay que contarlo antes de usar la regla.

La regla del "pero" en el léxico

Accuracy por grupo en las 400 reseñas, con la regla del "pero"

peso después de "pero"	todas	sin neg. ni contr.	con negación	con contraste
×1 (sesión 7)	0.825	0.972	0.788	0.338
×2	0.950	0.972	0.917	0.963
×3	0.955	0.972	0.917	0.988

Cuándo falla: "Muy rico todo, pero el parqueadero es pequeño." La queja de después del "pero" es un detalle; la reseña es positiva.

Grupo con contraste

0.338 → 0.963

razonable +1 · pero · seco −1 × 2 = −1

El punto devuelve el peso a 1: "rica, pero cara. El mesero fue amable." suma 0.

En este corpus la parte que decide siempre va después del "pero". En el suyo hay que contarlo antes de usar la regla.

"Pero" también es stopword

El mismo léxico con dos reglas, antes y después de quitar stopwords

¿Está en la lista de stopwords de NLTK?

pero	no	ni	nada	sin
muy	aunque	sino	nunca	

Ámbar: incluida en la lista. El pipeline del Módulo 1 la elimina.

```
el menú fue razonable, pero el ajiaco no estaba rico
→ menú día razonable ajiaco rico
```

Léxico con negación y "pero"

0.950

con el texto completo

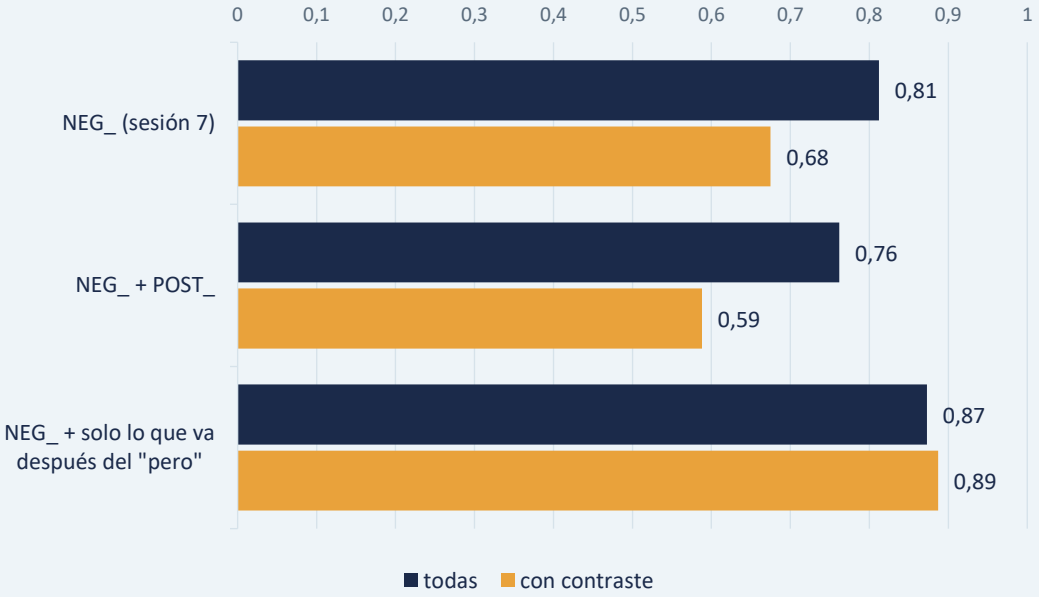
0.460

con el texto sin stopwords: igual que el léxico sin reglas de la sesión 7

Las stopwords se revisan por tarea. Para opiniones, la lista de NLTK borra justo las palabras que hacen el trabajo.

La misma idea en el modelo supervisado

TF-IDF + Regresión Logística · validación cruzada de 5 pliegues · accuracy



0.812 → 0.762

Marcar con POST_ empeora el modelo. La idea que funcionó con NEG_ aquí no sirve.

Quitar texto sí funciona

```
"El menú fue razonable, pero el
ajiaco estaba seco."
→ el ajiaco estaba seco
```

¿Por qué POST_ empeora el modelo? Lo vemos en la siguiente.

¿Por qué POST_ empeora el modelo?

NEG_ cambia el significado de la palabra · POST_ solo la cambia de columna

amable

10

reseñas de las que el modelo aprende el peso de la columna

POST_amable

1

reseña: la misma palabra, en otra columna, casi sin datos

112 de 346 columnas

son POST_ y todas salen de las mismas 80 reseñas con contraste.

NEG_rica significa lo contrario de **rica**: vale la pena una columna aparte.

POST_seco significa lo mismo que **seco**: separarlas solo divide la evidencia, y lo que va antes del "pero" sigue sumando.

Una regla que funciona en el léxico no se traduce automáticamente en una buena característica para el modelo.

¿De quién es el error?

Léxico con negación y "pero": 0.950 · los 20 errores, leídos uno por uno



12 · Etiqueta equivocada

"La carne tenía buen sabor. Repetiría sin dudarlo." → etiquetada negativa

6 · Ventana de negación corta (sesión 7)

"no estaba en su punto": punto queda a 4 palabras del no

2 · Choque de stems (Módulo 1)

salió → sal ← salado: "el menú salió costoso" resta dos veces

Con ventana 4 el léxico sube a 0.965. El techo con estas etiquetas es 0.970. Una etiqueta también es una hipótesis.

Seis frases que nadie previó

Los dos mejores métodos del corpus frente a textos con otro estilo · predicción y probabilidad

frase	real	léxico	supervisado	preentrenado
Muy rico todo, pero el parqueadero es pequeño.	positivo	positivo	positivo · 0.55	
No solo estaba rica, estaba deliciosa.	positivo	sin decisión	positivo · 0.54	
Ese ajiaco estaba de otro planeta.	positivo	sin decisión	negativo · 0.54	
La atención, un desastre.	negativo	sin decisión	negativo · 0.59	
No es barato, pero vale cada peso.	positivo	positivo	positivo · 0.51	
Pésimo. Esperamos una hora y la sopa llegó tibia.	negativo	sin decisión	positivo · 0.55	

Ámbar: error o sin decisión. Supervisado: TF-IDF + NEG_ + solo después del "pero", entrenado con las 400 reseñas.

Léxico: 2 de 6 · Supervisado: 4 de 6, todas con probabilidad menor que 0.60.

Un modelo preentrenado

pysentimiento · RoBERTuito: un modelo de lenguaje que ya leyó mucho español antes de llegar a nuestro corpus

1 Preentrenamiento

Lee millones de tuits en español y aprende cómo se usan las palabras en contexto.

2 Ajuste

Lo entrenan con tuits etiquetados como POS, NEU o NEG.

3 Uso

Nosotros solo lo aplicamos. Cero etiquetas propias para entrenar.

La decisión de diseño: el modelo da tres probabilidades y nuestro corpus tiene dos clases. Comparamos solo POS contra NEG y contamos aparte cuántas veces ganó NEU.

En Colab: `pip install pysentimiento · create_analyzer(task="sentiment", lang="es")`

Pérez, Giudici y Luque (2021). pysentimiento: A Python toolkit for opinion mining and social NLP tasks.

Los tres enfoques, lado a lado

La fila del preentrenado se llena en vivo con la demo

método	400 reseñas	con contraste	seis frases nuevas	etiquetas para entrenar	tiempo · 400 textos
Léxico + negación (ventana 4) + "pero"	0.965	0.963	2 de 6	0	menos de 1 s
TF-IDF + NEG_ + solo después del "pero"	0.873	0.887	4 de 6	400	menos de 1 s
Preentrenado (pysentimiento)				0	

Para anotar en vivo: accuracy en las 400 reseñas · cuántas de las seis frases acierta · tiempo · porcentaje de NEU · qué dice en las 12 reseñas con etiqueta equivocada.

El supervisado se mide con validación cruzada; el preentrenado no se entrena, así que se mide directamente sobre las 400.

¿Cuándo usar cada enfoque?

No hay un ganador: hay preguntas que cada uno responde mejor

Léxico con reglas

Gana en

Cero etiquetas · cada predicción se explica palabra por palabra · instantáneo

Pierde en

Solo conoce las palabras y construcciones para las que se escribió

Supervisado

Gana en

Aprende el vocabulario de su dominio · liviano · F1 medible con validación cruzada

Pierde en

Necesita etiquetas · fuera de su estilo adivina con probabilidades cercanas a 0.5

Preentrenado

Gana en

Trae conocimiento del español · cero etiquetas propias · maneja frases nuevas

Pierde en

Lento y pesado · no se explica con una lista · entrenado con tuits, no con su dominio

La rúbrica de la Actividad 1 premia conclusiones que justifican cuándo conviene cada opción.

Actividad 1 · el reporte de 2 páginas

Clasificador de texto · notebook + reporte · 20 % · una sección por criterio de la rúbrica

1.5	**Implementación técnica**	Tarea, clases y ejemplos por clase · partición o validación cruzada · sin fuga de duplicados	*Sesión 6*
1.5	**Uso de la representación**	BoW o TF-IDF con evidencia: tabla de preprocesamiento con F1 ± desviación	*Sesión 7 · tabla de preprocesamiento*
1.0	**Evaluación del desempeño**	Línea base, accuracy, F1 macro y matriz de confusión, interpretadas	*Sesiones 6 y 8 · en su corpus*
1.0	**Análisis e interpretación**	Errores clasificados por causa · cuántos son de etiqueta · una mejora concreta	*Sesión 8 · método o etiqueta*

Cada afirmación del reporte lleva una cifra de su notebook. "El modelo funciona bien" no es un resultado.

Actividad 2 · el video de 5 minutos

Análisis de sentimientos · 20 % · un bloque por criterio · el tiempo es parte de la nota



0:00–0:45	**El problema y los datos**	Qué opinan los textos, cómo etiquetaron, cuántos por clase
0:45–2:00	**El modelo**	Su modelo, léxico o supervisado · qué hicieron con la negación y con el "pero"
2:00–3:15	**Resultados**	Predicciones organizadas · su modelo frente al preentrenado · aciertos y fallos
3:15–4:30	**Métricas**	Accuracy, F1 macro, matriz de confusión y resultados por grupo
4:30–5:00	**Una limitación concreta**	Un error real de su corpus y por qué ocurre

La limitación lleva un ejemplo de su corpus. "El modelo tiene limitaciones" no suma puntos.

Para llevarse del curso

01 Cada decisión del pipeline es una hipótesis: se mide por tarea. Las stopwords, el stemming y la ventana de negación se ganaron o perdieron su lugar con una cifra.

02 Antes de cambiar de modelo, lean los errores. A veces el que se equivoca es la etiqueta.

03 Un 0.96 en validación cruzada mide el corpus, no el idioma. Los modelos preentrenados existen para lo que ningún corpus de 400 textos alcanza a cubrir.

Entrega · domingo 8 de noviembre

Actividad 1: notebook ejecutado en Colab + reporte de 2 páginas en PDF
Actividad 2: video de 5 minutos con su notebook ejecutado